중 앙 법 학 회
중앙법학 제28집 제3호 2026년 09월
Chung-Ang Law Association
CHUNG-ANG LAW REVIEW
Vol. 28, No. 3, September 2026

민간 AI '헌법'의 행동 구현에 대한 공법적 통제

— 범용모델 공급자의 규범번역권력을 중심으로 —

김 민 규* · 박 상 영** · 남 한 결***

〈 차 례 〉

Ⅰ. 서론
Ⅱ. 민간 AI 헌법의 규범구조와 평가가능성
Ⅲ. 규범번역권력에 대한 공법적 통제와 행동보증
Ⅳ. 공법적 행동보증의 법적 효과와 입법모형
Ⅴ. 결론

* 주저자, KAIST 문술미래전략대학원 겸직교수, 변호사
** 공저자, 서울대학교 일반대학원 법학과 석사과정
*** 공저자, 부산대학교 공공정책학부

Ⅰ. 서론

1. 문제의 제기

생성형 인공지능 사업자는 모델이 어떠한 요청을 받아들이거나 거절할 것인지, 충돌하는 지시 가운데 무엇을 우선할 것인지, 안전성·정직성·도움성 사이의 충돌을 어떻게 조정할 것인지, 외부도구 사용을 어떠한 조건에서 허용할 것인지에 관한 원칙과 규칙을 자연어 문서로 제시하고 있다. Anthropic의 Claude's Constitution과 OpenAI의 Model Spec이 대표적이다.[1] 이러한 명칭이 곧 국가헌법과 같은 법적 성질을 의미하는 것은 아니며, 법적 의미는 이러한 문서가 실제 모델행동의 형성·설명·평가에서 수행하는 기능에 따라 판단되어야 한다.

자연어로 표현된 규범은 학습과 배포과정의 여러 단계를 거쳐 실제 모델행동에 반영될 수 있지만, 공개문서와 실제 행동이 일치한다고 전제할 수는 없다. 동일한 규범 아래에서도 모델판이나 배포상태에 따라 행동이 달라질 수 있고, 문서의 개정과 생산모델에 대한 반영 사이에도 시차가 존재할 수 있기 때문이다. 외부에서는 규범과 행동을 일부 관찰할 수 있지만 그 사이의 구현수단은 주로 공급자가 통제한다. 따라서 법적 평가에서는 문서 자체뿐 아니라 특정한 규범과 특정한 모델상태의 행동 사이에 성립하는 관계를 포착할 필요가 있다.[2]

이러한 문제는 하나의 범용모델이 복수의 제품·서비스에 공통적인 상류 구성

---

1) Anthropic, Claude's Constitution (Jan. 2026), pp. 2-6, 14-20, 81, https://www-cdn.anthropic.com/9214f02e82c4489fb6cf45441d448a1ecd1a3aca/claudes-constitution.pdf; OpenAI, Model Spec, version Aug. 18, 2026, "Overview" 및 "The chain of command," https://model-spec.openai.com/2026-08-18.html(최종방문일 2026. 8. 28.)

2) Anthropic, 앞의 문서(주 1), pp. 2, 81; OpenAI, "Inside Our Approach to the Model Spec" (Mar. 25, 2026), "What the Model Spec is not," "Being realistically aspirational" 및 "How we identify gaps and drive updates," https://openai.com/index/our-approach-to-the-model-spec/ (최종방문일 2026. 8. 28.).

요소로 공급될 때 더욱 중요해진다. 범용모델을 공급받아 제품·서비스를 구성하는 하류사업자(downstream provider 또는 downstream operator)는 공급자가 제시한 행동특성을 전제로 제품설계와 위험통제를 구성할 수 있으므로, 모델 판이나 배포구성의 변경은 여러 하류서비스의 공통된 설계전제에 동시에 영향을 미칠 수 있다. 어느 판본에서 무엇이 달라졌는지를 확인할 수 없다면 종전의 위험통제가 여전히 유효한지도 판단하기 어렵다.

현행 「인공지능 발전과 신뢰 기반 조성 등에 관한 기본법」은 자율적 검·인증 지원, 일정한 인공지능시스템의 안전의무, 고영향 인공지능의 위험관리·설명·인적 감독 등 여러 규율수단을 두고 있다. 따라서 문제는 인공지능 규율의 부재가 아니라, 복수의 하류서비스에 공통 공급되는 범용모델에서 특정한 명세판–모델판–배포구성의 행동상태와 그 변경 후의 현재성을 독립된 확인단위로 포착할 필요가 있는지에 있다. 국내의 인공지능 관련 감독과 사전적정성 검토 역시 사업자가 제출한 자료와 위험완화조치를 바탕으로 적법성 및 보호조치를 검토하고 있으나, 이러한 절차가 곧 특정 모델상태의 실제 행동을 판본별로 평가하고 그 현재성을 확인하는 제도를 의미하지는 않는다.[3)]

2. 연구질문과 선행연구

민간 사업자가 어떠한 가치체계를 선택하여야 하는지 또는 하나의 표준적인 'AI 헌법'을 마련하여야 하는지가 이 논문의 직접적인 문제는 아니다. 문제의 초점은 자연어 규범이 범용모델의 행동으로 구현되고 그 구현상태가 변경·배포될 수 있는 구조에서, 규범과 행동 사이의 관계를 공법이 어떠한 객체로 포착하고

3) 개인정보보호위원회, "개인정보위, 오픈AI에 과태료 부과 및 개선권고", 2023. 7. 27.; 같은 위원회, "개인정보위, 인공지능 친구 '카나나' 서비스 관련 사전적정성 검토 결과 심의·의결", 2025. 3. 13.; 같은 위원회, "네이버 검색 인공지능 에이전트 서비스('AI Tab') 사전적정성 검토 결과 의결", 2026. 5. 31.; 카카오, "책임 있는 AI 개발을 위한 실천, Kanana-1.5-9.8B 안전성 평가 결과 공개", Tech Ethics 제22호(각 공식 웹자료, 최종방문 2026. 8. 28.).

통제할 것인지에 있다. 이러한 구조는 네 가지 질문을 제기한다. 첫째, 현행 인공지능법제가 존재함에도 범용모델의 규범–행동 관계와 그 변경을 별도로 포착할 모델층의 문제가 남는가. 둘째, 자연어 행동규범과 특정 모델판·배포구성의 행동 사이의 관계는 어떠한 조건에서 평가 가능한 공법상 객체가 되는가. 셋째, 국가는 민간 규범의 가치내용을 승인하지 않으면서 대외적 행동주장의 정확성과 독립적인 법정 최소선을 어디까지 요구할 수 있는가. 넷째, 그러한 평가의 효력은 어느 모델상태와 기간에 미치며, 모델판이나 배포구성의 변경은 그 현재성에 어떠한 영향을 미치는가.

한편 인공지능의 행동규범과 거버넌스에 관한 연구는 민간이 설정한 규범의 성격과 정당성, 자율규제와 공적 통제의 관계를 여러 관점에서 다루어 왔다. 국내에서는 'AI 헌법'을 인공지능 규제 거버넌스의 관점에서 검토하거나 인공지능 윤리규범·표준과 규제된 자율규제의 관계를 분석하는 논의가 제시되었고, 생성형 AI 플랫폼의 약관·이용정책과 기술적 집행을 결합된 거버넌스 구조로 파악하는 연구도 이루어졌다. 국외에서는 민간 사업자가 정한 AI constitution의 정당성과 공적 헌법화 가능성 또는 복수의 AI constitution이 병존하는 규범적 구조가 논의되고 있다. 이러한 연구는 민간의 행동규범이 단순한 내부 기술문서를 넘어 규범형성·거버넌스의 문제를 제기한다는 점을 보여 준다.[4] 다만 그 주된 관심이 규범의 형성주체·내용·절차와 정당성에 있다면, 본 논문의 관심은 이미 선택된 규범이 특정한 모델상태의 행동으로 구현되고 그 구현상태가 변경·배포되는

4) 이창민, "인공지능에 대한 합헌적 규제 거버넌스론 — '클로드 헌법'에 대한 논평으로부터 —",『법조』제75권 제2호, 2026, 201-205면 및 217-222면; 이병준·문현지, "생성형 AI와 투명성",『소비자문제연구』제56권 제3호, 2025, 171-172면; 고학수·박도현·이나래, "인공지능 윤리규범과 규제 거버넌스의 현황과 과제",『경제규제와 법』제13권 제1호, 2020, 29-30면; 이효진, "규제된 자율규제 형태로서 인공지능 표준(AI Standards)의 규범적 쟁점과 과제",『법과 기업 연구』제15권 제2호, 2025, 60-69면; Gilad Abiri, "Public Constitutional AI," 59 Georgia Law Review 601 (2025), pp. 641, 648-652; Simon Goldstein & Peter N. Salib, A Thousand AI Constitutions (2026), pp. 5-12, https://philarchive.org/archive/GOLATA-3; 이외에 생성형 AI 플랫폼의 약관·이용정책 등 사적 규범과 거부·제한·정지 등의 기술적 집행을 하나의 '규칙–집행 결합체'로 파악하고, 그 정당성을 명확성·투명성·이유제시·구제 및 감사 가능성의 관점에서 분석하는 연구도 제시되고 있다. 유성희·서효중, "생성형 AI 플랫폼 거버넌스의 절차적 신뢰",『시민사회와 NGO』제24권 제1호, 2026, 47-51면.

구조에 있다.[5]

다른 한 흐름은 자연어 행동규범을 학습·정렬·추론과정에 연결하고, 그 결과가 실제 모델행동에 어느 정도 나타나는지를 기술적으로 평가하는 문제를 다룬다. 관련 연구는 자연어 원칙을 자기비평·학습·추론 등에 연결하여 모델행동을 형성하는 방법과 공개된 행동사양을 시험항목으로 전환하여 모델응답의 부합도를 측정하는 방법을 제시해 왔다.[6] 이러한 연구는 자연어 규범과 모델행동의 관계가 원리적으로 관찰·평가 불가능한 것은 아님을 보여 준다. 다만 그 평가결과가 어느 모델판·배포구성에 귀속되는지, 이후의 변경에도 계속 유효한지, 그리고 그 결과에 어떠한 법적 효과를 부여할 것인지는 기술적 부합평가와 구별되는 문제이다.

이러한 선행연구와 이 논문의 분석대상은 서로 인접하지만 일치하지 않는다. 본 논문은 이미 선택된 규범을 특정한 모델판·배포구성의 행동으로 구현하고 그 구현상태를 변경·배포할 수 있는 공급자의 사실상 지배가능성을 포착하기 위하여 '규범번역권력(norm-translation power)'이라는 분석개념을 구성한다. 규범형성에 관한 연구가 행동규범의 형성주체·절차·정당성을 주로 문제 삼는다면, 이 개념은 규범의 선택 이후 그것이 특정한 모델상태의 행동으로 구현되고 그 구현상태가 변경·배포되는 구조에 초점을 둔다. 또한 기술적 행동평가가 규범과 행

5) 나아가 국내에서는 현행 고영향 인공지능의 영역별 열거만으로 새롭게 등장하는 위험을 충분히 포착하기 어렵다는 문제의식 아래, 기술의 명칭보다 실제 수행기능과 용례를 중심으로 규율대상을 구체화하려는 연구도 제시되고 있다. 본 논문은 이러한 기능·용례별 고위험성 선별문제와 달리, 공급자가 계속 통제하는 범용모델의 규범–행동 관계를 어떠한 판본과 배포상태에 귀속시켜 평가할 것인지를 문제 삼는다. 김민규, "직업규제 영역의 인공지능 기능대체와 고위험성 판단기준—직업의 자유 제한 법리에 기초한 기능적 등가성 기준의 제안—", 『법조』 제75권 제2호, 2026, 403-407면 및 429-430면.

6) Yuntao Bai et al., "Constitutional AI: Harmlessness from AI Feedback," arXiv:2212.08073 (2022), pp. 1-4; Anthropic, Collective Constitutional AI: Aligning a Language Model with Public Input, Policy Memo (2023), pp. 1-2; Alan Guo & Jason Wolfe, "Introducing Model Spec Evals," OpenAI Alignment Research Blog (Mar. 25, 2026), https://alignment.openai.com/model-spec-evals/; Ahmed, Ahmed et al., "SpecEval: Evaluating Model Adherence to Behavior Specifications," arXiv:2509.02464v2 (2025), pp. 1-6; Arya Jakkli, Senthooran Rajamanoharan & Neel Nanda, "How Well Do Models Follow Their Constitutions?," arXiv:2605.24229v1 (2026), pp. 1, 5.

동의 부합을 관찰하는 방법을 다룬다면, 공법상 문제는 그 평가에 사용된 증거와 판단을 어느 모델판·배포구성·범위·시점에 귀속시킬 것인지, 그리고 대외적 행동주장의 정확성에 관한 판단과 독립적인 법정 위해·권리 기준선의 판단을 어떠한 법적 근거와 효과로 구별할 것인지에 있다. 이에 따라 평가의 증거와 효력범위를 특정 모델상태에 결부하는 판본결박과 행동주장의 불일치·법정 기준선의 중대한 부적합·평가의 특정성 또는 현재성 결여·절차위반에 상이한 법적 효과를 부여하는 효과분리가 요구된다. 특히 평가의 현재성을 확인할 수 없다는 사실은 그 자체로 법정 기준선의 위반을 의미하지 않으며, 보증상태의 변경 역시 기존 적합결정의 효력변경과 동일시될 수 없다.

3. 연구의 방법과 범위

법령·판례·행정자료는 공법상 의무와 법적 효과를 판단하는 근거로 사용하고, 기술연구는 자연어 규범의 구현가능성과 행동평가의 방법 및 한계를 확인하는 자료로 활용한다. 사업자가 공개한 Constitution, Model Spec 및 관련 문서는 공급자가 제시하는 행동규범의 내용과 권위구조, 판본 및 적용범위를 파악하기 위한 자료로 활용한다. 비교법 자료는 공시, 모델평가, 위험기반 규율 및 변경통제와 같이 기능적으로 유사한 제도의 구성방식을 확인하는 데 활용하되, 그 제도나 법적 효과를 국내법에 그대로 전제하지 않고 국내 헌법과 행정법에 따라 수용가능성을 별도로 판단한다.[7]

분석대상은 공급자가 배포 이후에도 모델판 또는 모델행동에 유의미한 영향을 미치는 배포구성을 통제하면서, 해당 모델을 복수의 제품·서비스에 공통적으로 제공하는 서비스형 범용모델을 중심으로 한다. 이에 비하여 공급 이후 제3자가 가중치나 시스템 구성을 독립적으로 수정·배포하고 원공급자가 그 행동상태를 계속 통제하지 않는 공개 가중치 모델에는 동일한 규율구조를 전제하기 어렵

7) National Institute of Standards and Technology, Artificial Intelligence Risk Management Framework (AI RMF 1.0), NIST AI 100-1 (2023), pp. 5-6, 20-27.

다. 따라서 변경보고, 판본특정 및 평가의 현재성에 관한 의무의 범위도 공급자가 실제로 행사하는 통제와 확보할 수 있는 증거의 범위에 대응하여 정하여야 한다.

연구범위는 범용모델의 규범-행동 관계와 그 평가가능성, 판본특정성 및 공법적 통제에 한정한다. 학습데이터와 저작권, 개인정보 처리 자체의 적법성, 개별 생성물에 의한 권리침해, 민·형사책임 및 경쟁법상의 문제는 각각 독립된 법적 쟁점을 형성하므로 직접적인 분석대상에서 제외한다. 다만 이러한 법영역의 규범이 모델행동에 적용되는 기존 법질서의 내용이나 모델층 평가의 법적 근거를 확정하는 데 필요한 경우에는 그 범위에서 검토한다.

Ⅱ. 민간 AI 헌법의 규범구조와 평가가능성

1. 기능적 모델행동명세

'AI 헌법'은 국가헌법과 동일한 법적 개념이 아니다. Anthropic은 Claude's Constitution이라는 명칭을 모델의 목적·사명과 다른 주체와의 관계를 자연어로 구성하고, 다른 지침과 충돌할 때 상위의 행동기준으로 기능하도록 설계하였다는 의미에서 사용한다. 그러나 이러한 문서는 외부 법질서에서 국가권력과 하위 법규범을 구속하는 최고규범이 아니라 사기업이 작성한 사적 문서이다. 그 법적 의미는 헌법이라는 명칭 자체가 아니라, 사적으로 설정된 자연어 규범이 모델의 목적·원칙과 지시의 우선순위를 조직하고 행동형성의 기준으로 기능한다는

점에서 찾을 수 있다.[8)]

이러한 기능은 '헌법'이라는 명칭이나 단일한 문서형식에 한정되지 않는다. OpenAI는 유사한 기능을 수행하는 문서를 Model Spec이라 부르고 있으며, 행동기준은 규칙집·안전정책·평가기준 등 여러 문서에 분산되어 존재할 수도 있다. 따라서 사업자가 사용하는 명칭이나 문서형식과 관계없이, 모델이 어떠한 목적·원칙과 지시를 어떠한 권위관계에서 따르도록 설계되어 있는지, 충돌하는 요구를 어떻게 조정하고 어떠한 예외를 두는지, 그리고 그러한 기준이 어느 모델·판본·배포범위에 적용되는지를 식별할 수 있게 하는 문서 또는 문서군을 '모델행동명세(model behavior specification)'라 한다. 이는 이미 확립된 법률상 개념을 전제하는 것이 아니라, model specification 또는 behavior specification 계열의 용례를 법적 분석을 위하여 기능적으로 구성한 개념이다.

모델행동명세는 우선 모델행동을 형성·평가하기 위한 설계기준으로 기능한다. 공급자가 그 전부 또는 일부를 모델카드·기술문서·안전보고서·API 문서 등을 통하여 외부에 제시하는 경우에는 이용자와 하류사업자가 제품설계·회귀시험·위험통제에 활용하는 행동정보의 기능도 갖는다. 그러나 자연어 원칙이 학습·사후정렬·평가 또는 런타임 지시에 이용된다는 사실만으로 해당 문서가 국가법상 법규범으로 전환되거나 모델 자체가 법적 수범자가 되는 것은 아니다. 모델행동명세의 사적 규범성, 실제 행동에 대한 기술적 구현, 외부 법질서에서의 법적 효력은 서로 구별되어야 한다.

모델행동명세는 약관·이용정책 및 실제 배포구성과도 구별된다. 약관과 이용정책이 사업자와 이용자 사이의 권리·의무 또는 허용되는 이용행위를 정하는 데 주된 기능이 있다면, 모델행동명세는 모델이 어떠한 방식으로 행동하도록 설계되었는지에 관한 기준을 대상으로 한다.[9)] 한편 시스템·개발자 지시, 분류기·라우터·메모리·도구권한 등의 구현요소는 모델행동명세와 결합하여 실제 행동을 형

8) Anthropic, Claude's Constitution, 특히 "On the word 'constitution'"; OpenAI, Model Spec, "Overview," "Instructions and levels of authority" 및 "The chain of command."

9) Anthropic, Claude's Constitution, 앞의 문서(주 1), pp. 14-20; OpenAI, Model Spec, 앞의 문서, "Definitions"의 Developer 설명 및 "The chain of command."

성할 수 있으므로, 명세가 존재한다는 사실만으로 그 내용이 특정 모델판의 배포 행동에 그대로 구현되어 있다고 볼 수 없다. 따라서 모델행동명세는 규범과 실제 행동을 동일시하기 위한 개념이 아니라, 특정 모델상태의 행동을 평가할 때 어느 규범을 그 출발점으로 삼을 것인지를 특정하기 위한 개념이다.

2. Claude Constitution과 Model Spec의 비교

*Claude Constitution*과 *Model Spec*은 모두 범용모델의 행동기준을 자연어로 조직하지만, 그 규범형식과 권위구조에는 차이가 있다. *Claude Constitution*은 가치·성격과 판단이유를 비교적 서술적인 방식으로 제시하고, hard constraints와 Anthropic·operator·user 사이의 관계적 권한구조 아래에서 상충하는 요구를 맥락적으로 조정하도록 구성되어 있다.[10] 또한 지속적으로 수정되는 'living framework'로 제시되므로 문서의 개정시점과 실제 모델에 대한 반영시점은 구별될 수 있다.

반면 Model Spec은 root–system–developer–user–guideline으로 이어지는 권위수준을 명시하고, 규칙·기본값·예외를 상대적으로 구조화된 형식으로 제시한다. 공개 저장소를 통하여 변경기록과 과거 판본도 관리한다. 그러나 공개된 사양이 실제 배포행동의 모든 결정요소를 포괄하는 것은 아니며, 비공개 상위지시나 제품별 구현요소가 함께 작동할 수 있다. 따라서 두 문서 모두 공개된 규범문서의 판본과 특정 시점에 실제로 배포되는 모델의 행동상태를 동일시할 수 없다.[11] [12]

양자의 차이는 다음과 같이 정리할 수 있다.

---

10) Anthropic, 앞의 문서(주 1), pp. 2, 5-9, 14-20, 47-49.

11) OpenAI, Model Spec, 앞의 문서, "Instructions and levels of authority" 및 "The chain of command."

12) OpenAI, "Inside Our Approach to the Model Spec" (Mar. 25, 2026), "What the Model Spec is not," "Being realistically aspirational" 및 "How we identify gaps and drive updates," https://openai.com/index/our-approach-to-the-model-spec/ (최종방문 2026. 8. 28.).

〈표 1〉 Claude Constitution과 OpenAI Model Spec의 규범구조 비교

비교축	Claude Constitution	OpenAI Model Spec	분석상 의미
규범형식	가치·성격과 전체론적 판단	권위수준·규칙·기본값·사례	특정 문언형식을 표준화하지 않음
권위구조	관계적 principal과 책임배분	root–system–developer–user–guideline의 권위위계	권위관계와 지시권한을 식별
충돌처리	맥락·가치·관계에 따른 조정	상하위 지시와 규칙·예외에 따른 해결	충돌해결 기능 자체를 평가
예외·경계	hard constraints와 맥락적 판단	적용조건·exceptions·defaults	원칙뿐 아니라 예외구조도 식별
판본·적용	living framework와 반영시차	변경기록·과거 공개판본과 비공개 구현층	규범판과 실제 적용 모델판을 구별

공통적으로 확인되는 것은 목적과 권한, 충돌과 예외, 적용범위를 어떠한 형태로든 조직하여야 한다는 점이다. 따라서 모델행동명세를 기능적으로 파악하는 것은 특정 사업자의 문서형식을 일반화하거나 하나의 가치체계·작성방식을 표준화하려는 것이 아니다. 중요한 것은 서로 다른 규범형식 아래에서도 어떤 기준이 어느 모델상태에 적용되는지, 그리고 그 기준과 실제 행동 사이의 대응관계를 식별·평가할 수 있는지 여부이다.

3. 구현경로와 행동적합성 평가

모델행동명세가 공법상 평가의 출발점이 되려면 자연어 규범이 실제 모델행동의 형성과 연결될 수 있고, 그 결과를 외부에서 일정하게 관찰·평가할 수 있어야 한다. 다만 규범을 행동형성에 사용할 수 있다는 것, 실제 행동이 그 규범에 부합한다는 것, 그리고 그 규범이 해당 행동을 인과적으로 발생시켰다는 것은 서로 다른 명제이다.

자연어 행동규범은 학습자료의 구성, 사후정렬, 추론과정, 평가 및 런타임 지시 등 여러 경로를 통하여 모델행동에 반영될 수 있다. 관련 기술연구는 자연어

원칙을 자기비평·학습·추론 등에 연결하는 방법이 실제로 구현 가능함을 보여 준다. 그러나 공개된 Constitution이나 Model Spec 전체가 특정 생산모델에 그대로 내재되어 있다거나 같은 명세가 모든 배포환경에서 동일한 행동을 낳는다고 볼 수는 없다. 실제 행동은 학습결과뿐 아니라 상위지시, 분류기·라우터, 도구 권한과 제품설정 등 복수의 요소에 의하여 형성되기 때문이다.[13]

규범과 실제 행동의 대응관계 역시 일정한 범위에서 시험할 수 있다. 공개된 행동사양과 모델응답의 일치도를 측정하거나 적대적·다회차 상황에서 특정 모델판이 제시된 행동기준을 얼마나 따르는지를 평가하는 방법이 개발되어 왔다.[14] 이는 자연어 규범과 모델행동의 관계가 원리적으로 관찰 불가능한 것은 아님을 보여 준다. 명세의 형식에 따라 적용조건·예외·충돌상황 또는 대표·경계상황에서의 선택을 시험항목으로 구성할 수 있다.

다만 이러한 평가결과를 곧바로 법적 의미의 '준수율'이나 실제 서비스의 위해 발생률로 읽어서는 안 된다. 결과는 특정 명세·모델판·시험문항·유도절차와 판정방법 아래에서 관찰된 일치·불일치를 나타낼 뿐이고, 자연어 규범의 모호성, 문항의 대표성, 판정오류와 평가적응 등의 한계가 개입할 수 있다.[15] 또한 행동이 명세와 부합한다는 사실만으로 그 행동이 해당 명세 때문에 발생하였다는 인과관계가 증명되는 것도 아니다.

따라서 공법적 평가에서 필요한 것은 모델 내부의 모든 인과기제를 해명하거나 특정한 학습·정렬기법을 강제하는 것이 아니다. 핵심은 어느 규범판이 어느 모델판·배포구성과 연결되어 있다고 제시되는지를 특정하고, 그 상태에서 관찰되는 행동이 평가대상으로 정한 행동기준과 어느 정도 대응하는지를 검증하는

13) Yuntao Bai et al., 앞의 논문, pp. 3-6; Anthropic, Collective Constitutional AI, pp. 1-2; Melody Y. Guan et al., "Deliberative Alignment: Reasoning Enables Safer Language Models," arXiv:2412.16339v2 (2025), pp. 3-6, 16; Chloe Li et al., "Model Spec Midtraining: Improving How Alignment Training Generalizes," arXiv:2605.02087v2 (2026), pp. 1-4.

14) Alan Guo & Jason Wolfe, 앞의 글; Ahmed Ahmed et al., 앞의 논문(주 6), pp. 1, 6; Arya Jakkli, Senthooran Rajamanoharan & Neel Nanda, 앞의 논문, pp. 1, 5.

15) Ahmed Ahmed et al., 앞의 논문(주 6), pp. 6-7; Arya Jakkli, Senthooran Rajamanoharan & Neel Nanda, 앞의 논문, pp. 5-10.

것이다. 그 결과는 특정한 규범·모델·배포상태와 평가조건에 결박된 잠정적 증거로 이해하여야 한다.

4. 판본결박과 공법상 평가객체

법적 판단은 그 대상을 특정할 수 있다는 것을 전제로 한다. 전형적인 비연결형 제조물에서는 인도 이후 제조자가 개별 물건의 성상을 일상적으로 계속 변경하지 않으므로 제품모델·제조번호 등을 통하여 대상을 비교적 안정적으로 특정할 수 있다. 그러나 서비스형 범용모델에서는 공급자가 배포 이후에도 모델판이나 행동에 유의미한 영향을 미치는 배포구성을 변경할 수 있으므로 이러한 전제가 그대로 성립하지 않는다.

동일한 서비스명이나 가변적인 모델 별칭이 유지되더라도 그 아래에서 제공되는 모델판이나 제품설정은 변경될 수 있다. 고정 모델 ID가 특정 스냅샷을 가리키는 경우와 별칭이 새로운 스냅샷을 가리키도록 변경되는 경우는 구별하여야 하고, 고정 모델 ID가 유지되더라도 요청 라우터·안전분류기·샘플링 등 서빙 인프라의 변경에 따라 관찰되는 행동에 차이가 생길 수 있다. 따라서 동일한 서비스명이나 모델 ID만으로 평가된 행동상태의 현재성을 보장할 수는 없다.[16)]

따라서 "이 모델은 안전한가" 또는 "이 모델은 행동명세를 준수하는가"라는 질문만으로는 공법상 판단대상이 충분히 특정되지 않는다. 어느 시점의 명세판이 어떤 모델판·배포구성과 연결되어 있었고 평가결과가 어느 상태에 귀속되는지를 함께 특정하여야 한다. 본 논문은 이를 '판본결박'이라 한다. 이는 단순한 버전표시가 아니라 평가대상인 모델상태와 그에 관한 증거·판단의 효력범위를 서로 결부하는 것을 의미한다. 동일한 명세판이라도 모델판이나 배포구성이 달라지면 행동이 달라질 수 있고, 명세가 개정되더라도 생산모델에 즉시 반영된다

16) OpenAI, "API Overview," "Backwards compatibility," https://developers.openai.com/api/reference/overview#backwards-compatibility; Anthropic, "Model IDs and versioning," https://platform.claude.com/docs/en/about-claude/models/model-ids-and-versions(최종방문일 2026. 8. 28.).

고 볼 수 없으므로 종전 평가를 다른 모델판이나 이후의 배포상태에 자동으로 승계할 수 없다.

판본결박이 모든 기술적 상태의 동결이나 개별 출력의 완전한 재현을 요구하는 것은 아니다. 결박대상은 공급자가 통제할 수 있고 평가된 행동에 유의미한 영향을 미치는 명세·모델·배포의 구성요소로 한정한다. 그 기능은 처분대상이 되는 모델상태를 특정하고, 시험·재현·현장자료의 증거귀속범위를 정하며, 판단의 객체적·시간적 효력을 한정하고, 이후의 변경으로 재평가가 필요한 범위를 식별하는 데 있다. 따라서 판본결박은 두 실체적 판단에 부가되는 기술적 절차가 아니라 그 판단을 특정한 모델상태에 귀속시키기 위한 선행조건이다.

모델행동명세, 위험관리체계, 평가증거와 보증상태도 구별하여야 한다. 모델행동명세는 대외적 행동주장의 정확성을 평가할 때 규범측 기준이 되고, 위험관리체계는 조직의 위험식별·완화·대응절차이므로 그것만으로 특정 모델판의 실제 행동을 증명하지 않는다. 시험·재현·현장자료 등 기술적 평가결과는 각 법적 판단을 뒷받침하는 증거이고, 보증상태는 그러한 증거에 기초하여 어떤 평가항목이 어느 객체·범위·시점에서 확인되었는지를 나타내는 상태정보이다.[17]

이에 따라 대외적 행동주장의 정확성을 판단할 때의 평가객체는 특정한 명세판–모델판–배포구성에서 공표된 행동특성과 실제 행동 사이의 대응관계이고, 법정 위해·권리 기준선에 대해서는 같은 모델상태에 독립적인 법률상 기준을 적용한다. 판본결박은 각 판단에 사용된 증거와 그 효력범위를 한정하며, 변경 후 종전 증거의 현재성은 영향을 받은 평가항목별로 다시 확인하여야 한다. 이때 보증상태는 모델 전체에 붙는 안전 합격표지나 공급허가가 아니라 이러한 평가의 현재 유효범위를 나타내는 상태정보이다. 강화대상에 대한 출시 전 적합결정에 별도의 시장접근효가 부여되는 경우 그 결정은 보증상태와 구별되는 독립적인 법

17) ISO/IEC 42001:2023, Information Technology—Artificial Intelligence—Management System; ISO/IEC 42006:2025, Requirements for Bodies Providing Audit and Certification of Artificial Intelligence Management Systems; Marie Davidsen Buhl et al., "Safety Cases for Frontier AI," arXiv:2410.21572 (2024), pp. 5-7; Arthur Goemans et al., "Safety Case Template for Frontier AI: A Cyber Inability Argument," arXiv:2411.08088 (2024), pp. 3-6.

적 판단이며, 보증상태의 변경만으로 그 효력이 당연히 변경되는 것은 아니다.[18]

Ⅲ. 규범번역권력에 대한 공법적 통제와 행동보증

1. 현행법상 모델층 공백

자연어 규범과 실제 모델행동의 관계를 기술적으로 특정·평가할 수 있다는 사실만으로 이를 곧 독립된 공법상 규율객체로 삼을 수 있는 것은 아니다. 먼저 현행법이 이미 포착하는 위험과 그럼에도 남는 규율단위의 차이를 구별하여야 한다. 여기서 말하는 모델층의 공백은 인공지능에 관한 법규가 존재하지 않는다는 의미가 아니라, 현행 규율의 객체·시점·증거구조와 특정한 규범–행동 관계 사이에 남는 불일치를 뜻한다.

현행 인공지능기본법은 생성형 인공지능 등에 대한 투명성의무(제31조), 일정한 인공지능시스템의 위험 식별·평가·완화 및 위험관리체계 구축의무(제32조), 고영향 인공지능에 대한 사전검토·확인절차와 위험관리·설명·인적 감독 등의 책무(제33조·제34조), 고영향 인공지능을 이용한 제품·서비스의 기본권 영향평가에 관한 노력의무(제35조 제1항)를 두고 있다. 개인정보 처리, 표시·광고 및 계약관계에도 각 개별법이 적용될 수 있고, 표시광고법 역시 사실적 표시의 실증과 공적 시정수단을 예정하고 있다. 따라서 범용모델이라는 이유만으로 현행법의 외부에 놓이는 것은 아니며, 본 논문이 말하는 모델층의 문제도 기존 법률과 별

18) European Union Agency for Cybersecurity, Guidelines on Assurance Continuity—Practical Change Scenarios for Certified ICT Products, version 1 (Dec. 10, 2025), pp. 14-19.

개의 실체기준을 당연히 새로 창설하여야 한다는 의미는 아니다.

비교법상 상류의 범용모델 자체를 직접 규율단위로 포착하는 입법도 존재한다. EU AI Act는 general-purpose AI model 공급자에게 기술문서 작성과 당국·하류사업자에 대한 정보제공 의무를 부과하고, systemic risk가 있는 모델에는 모델평가·시스템위험의 평가·완화, 중대사고 보고 및 사이버보안 의무를 추가한다. General-Purpose AI Code of Practice는 이러한 법정의무의 이행방법을 구체화한다.[19] 이는 범용모델 자체에 공법적 의무를 부과하는 것이 제도적으로 가능함을 보여 주지만, 공급자가 제시한 자연어 행동명세와 특정 모델판·배포구성의 실제 행동 사이의 대응관계를 독립적인 확인객체로 삼아 판본별 현재성을 평가하는 것과는 구별된다.

현행 의무를 구체적으로 해석·집행함으로써 특정 모델의 행동상태와 관련된 판본·평가자료 및 변경정보를 상당 부분 관리할 가능성도 열려 있다.[20] 특히 인공지능기본법 제32조의 수명주기 위험관리와 제34조의 위험관리·설명·인적 감독 및 문서작성 의무는 관련 자료를 포섭할 수 있고, 표시광고법의 실증·시정수단도 대외적 행동주장의 정확성을 통제하는 데 적용될 수 있다. 따라서 판본결박이라는 명칭이 현행법에 없다는 사실만으로 별도의 제도가 필요하다고 할 수는 없다. 문제는 기존 수단에 따라 확보된 증거가 어느 명세판–모델판–배포구성의 어떤 행동을 뒷받침하는지, 그리고 변경 후 그 평가를 어느 범위까지 계속 원용할 수 있는지를 공통적으로 특정할 수 있는가에 있다.

그 결과 세 가지 과제가 남는다. 첫째, 객체의 특정이다. 특정한 자연어 규범과 모델판·배포구성에서 관찰되는 행동의 대응관계가 어느 범위에서 평가되었는지

19) Regulation (EU) 2024/1689, arts. 53, 55; European Commission, Guidelines on the Scope of the Obligations for Providers of General-Purpose AI Models under the AI Act, C(2025) 5045 final, Annex, 18 July 2025; European Commission, General-Purpose AI Code of Practice—Transparency Chapter (July 2025); id., General-Purpose AI Code of Practice—Safety and Security Chapter (July 2025).

20) 안정빈, "AI기본법상 AI사업자 의무와 형사법상 조직책임—책임구조·의무층위·피해자구제를 중심으로—", 『법학논고』 제94집, 2026, 437-441면. 특히 저자는 제32조의 안전성 확보의무와 제34조의 위험관리·설명·인적 감독·문서작성 의무를 구별하여 검토하고, 제35조의 영향평가를 노력의무로 파악한다.

를 식별하여야 한다. 둘째, 시점의 특정이다. 상류모델의 행동특성과 변경은 개별 하류서비스에서 피해가 현실화되기 전에 여러 서비스의 공통전제에 영향을 미칠 수 있으므로, 사후적인 개별 피해의 발생시점과 구별하여 어느 모델상태를 어느 시점에 평가·확인할 것인지를 정할 필요가 있다.[21] 셋째, 증거와 현재성의 특정이다. 어느 명세판–모델판–배포구성이 평가되었고 이후의 변경에도 종전 평가가 유효한지를 확인하지 않으면 그 평가의 현재성을 판단하기 어렵다.

요컨대 본 논문이 검토하는 것은 기존 위험관리·실증·시정수단을 대체하는 새로운 규율체계가 아니라, 그 수단으로도 충분히 확보되지 않는 판본별 증거귀속과 변경 후 평가의 현재성을 어떠한 공법상 의무와 효과로 보완할 것인지의 문제이다.

2. 대외적으로 제시된 행동주장의 정확성 규율

(1) 사적 행동기준과 공법상 정확성의무의 구별

민간 사업자가 어떠한 행동원칙을 모델에 채택할 것인지는 원칙적으로 그 사업자의 선택에 속한다. 공급자가 스스로 행동기준을 정하였다는 사실만으로 그 내용이 공법상 의무가 되거나 국가가 이를 대신 집행하여야 하는 것은 아니다. 그러나 공급자가 특정한 행동특성을 공식적으로 외부에 제시하여 거래나 하류설계의 정보로 기능하게 한 경우에는 그 표시의 정확성이 별도로 문제된다. 행동기준의 내용은 사적으로 선택되더라도 그 주장이 적용되는 판본·범위를 특정하고 중요한 불일치를 정확히 표시할 의무는 정보비대칭과 오인을 방지하기 위하여 법률이 독립적으로 부과할 수 있다.

---

21) 모델의 응답 톤·거절방식·페르소나와 같은 행동특성이 정렬과 행동지침 등의 영향을 받아 형성될 수 있고, 그러한 행동특성이 인간–AI 상호작용에서 정동과 권위관계에 실제 효과를 발생시킬 수 있음을 분석한 연구로 양나리·신혜린, “의미 없는 대화, 의미 있는 충돌: 조롱형 AI 챗봇과의 말싸움 현상에 대한 문화적 분석.” 비교문화연구 77. (2026), 237-238면, 255-266면.

비교법에서도 사적으로 설정한 기준의 작성·공개·준수를 법률상 의무와 연결하는 사례를 확인할 수 있다. 캘리포니아의 현행 규율과 뉴욕의 2027년 1월 1일 시행예정 규율은 일정한 frontier AI 개발자에게 자체적인 규율체계의 작성·공개 또는 준수의무를 부과하고 그 위반에 법적 효과를 연결하는 입법례이다.[22] 다만 자기설정 기준의 미준수에 정보·절차의무 위반에 따른 제재를 연결할 수 있다는 것과 그 사적 기준 자체를 시장접근 제한의 실체기준으로 삼는 것은 구별하여야 한다. 자기공표의 정확성규율과 법정 위해·권리 기준선은 서로 다른 법적 근거와 효과를 가져야 한다.

(2) 계약·표시규율만으로 충분하지 않은 이유

행동주장이 계약내용이나 광고상 표시가 되는 경우에는 기존의 계약법·약관규제·표시광고법이 적용될 수 있으므로 행동보증이 이를 대체하여서는 안 된다.[23] 다만 범용모델에서는 하나의 상류 행동정보가 복수의 하류사업자의 설계·회귀시험·위험통제에 공통적으로 이용되고, 그 행동상태를 변경할 권한과 판본·평가정보는 주로 공급자에게 집중된다. 상류의 변경은 여러 거래관계에 동시에 영향을 미칠 수 있지만 개별 사후구제만으로는 어느 행동주장이 어느 모델판·배포구성에서 현재 유효한지를 공통적으로 회복하기 어렵다. 이러한 일대다 의존과 증거비대칭은 개별 거래법적 보호와 구별되는 공법상 정확성규율의 필요성을 뒷받침한다.[24]

따라서 대외적 행동주장의 정확성에 독립적인 공법개입을 정당화하려면 적어도 ① 행동정보가 복수의 하류설계에 공통적으로 이용되고, ② 변경권한과 핵심

22) Cal. Bus. & Prof. Code §§ 22757.12(a)-(b), 22757.15 (Transparency in Frontier Artificial Intelligence Act, effective Jan. 1, 2026); N.Y. Gen. Bus. Law art. 44-B, §§ 1421(1)-(4), 1427(1) (effective Jan. 1, 2027).

23) 이동진, "자율규제와 사적 질서", 『법조』 제72권 제4호, 2023, 159-164면; 「표시·광고의 공정화에 관한 법률」 제3조·제5조; 「약관의 규제에 관한 법률」 제6조·제10조·제12조; 대법원 2022. 4. 28. 선고 2019두36001 판결.

24) 김민규, "AI는 왜 믿음을 얻는가—AI-Washing, 판단외관, 그리고 AX 시대의 표지신의칙—", 『동아법학』 제112호, 2026, 33, 38-47면.

증거가 공급자에게 집중되며, ③ 변경효과가 여러 관계에 전파되고, ④ 개별 사후구제만으로 그 정보의 현재성을 회복하기 어려워야 한다. 이는 모델층 규율 일반의 성립요건이 아니라 정확성규율에 별도의 공법개입이 필요한지를 판단하기 위한 조건이다.

(3) 규율대상의 한계

정확성규율의 대상은 사업자가 표현하는 모든 가치·목표나 이상적 포부가 아니다. 국가가 도움성·안전성·가치철학과 같은 추상적 기준의 의미를 해석하여 이행 여부를 판단하기 시작하면 사실확인이 사적 규범내용의 심사로 변질될 수 있다. 따라서 대상은 공식적인 매체를 통하여 외부에 제시되고, 특정한 모델행동으로 관찰·반증할 수 있으며, 적용되는 모델판·배포범위를 합리적으로 특정할 수 있는 행동주장으로 한정하여야 한다. 특히 거래나 하류의 회귀시험·위험관리의 전제로 이용될 것을 합리적으로 예상할 수 있는 주장의 규율필요성이 크다.

일정한 사실정보나 기술적 표지를 정확하게 표시하도록 요구하는 것은 특정한 가치내용을 말하도록 강제하는 것과 동일하지 않다. 헌법재판소도 소비자의 선택에 필요한 중요정보의 표시·광고의무나 이미 유해매체물로 결정된 인터넷 정보에 대한 기술적 표시의무를 표현의 자유에 대한 제한으로 보면서도 그 목적·내용과 제한의 정도를 심사하여 허용한 바 있다.[25] 다만 행동주장의 정정·공표의무 역시 표현의 자유와 직업수행의 자유를 제한하므로, 정보비대칭과 중대한 오인의 방지에 필요한 범위를 넘어서는 안 되며 행정청이 이를 통하여 공급자가 표명하지 않은 가치기준을 추가해서도 안 된다.

25) 헌재 2012. 2. 23. 2009헌마318 결정; 헌재 2004. 1. 29. 2001헌마894 결정. 전자는 상조업자에게 소비자 선택에 필요한 중요정보를 표시·광고하도록 한 규율을, 후자는 이미 청소년유해매체물로 결정된 인터넷 정보에 대하여 필터링을 위한 전자적 표시를 하도록 한 규율을 각각 심사한 사건이다.

(4) 불일치의 효과와 법정 최소선과의 분리

자발적으로 공표한 행동기준과 실제 행동이 불일치한다는 이유만으로 모델의 출시·공급을 제한하면 사적 약속이 사실상 공법상 시장접근 기준으로 전환되고, 엄격한 기준을 공표할수록 더 큰 규제위험을 부담하게 하는 역유인도 생길 수 있다.

따라서 불일치의 직접적인 효과는 원칙적으로 정정·삭제, 불일치와 영향범위의 공개, 보증주장의 범위조정 및 필요한 재평가에 한정하여야 한다. 그것만으로 모델의 기능·언어·지역·이용자범위 또는 공급을 제한해서는 안 되며, 실제 행동이 별도로 법률이 정한 위해·권리의 최소기준에 중대하게 부적합한 경우에만 그 독립된 법적 근거에 따라 시장제한을 검토할 수 있다. 사적 행동주장은 공법상 최소기준을 창설하거나 변경하지 않는다.

행동주장의 변경을 정확히 고지할 공법상 의무가 인정되더라도 그것이 곧 개별 계약관계에서 변경에 대한 동의를 의미하는 것은 아니다. 변경정보의 제공은 행동주장과 실제 행동 사이의 대응관계의 현재성을 확보하기 위한 공법적 의무이고, 그 변경의 사법상 효력은 별도로 판단하여야 한다.

3. 법정 위해(危害)·권리 기준선

(1) 법적 출처와 모델층 평가의 성격

대외적 행동주장의 정확성규율과 달리, 법정 위해·권리 기준선은 공급자의 공표와 무관하게 적용되는 공적 최소선이다. 다만 이를 이유로 포괄적인 'AI 권리 목록'을 새로 만들 수는 없다. 기존 법률이 범용모델 공급자의 행위에 직접 적용되는 경우에는 그 법률이 실체적 근거가 되고, 행동보증은 특정 모델판의 행동증

거를 판본별로 확인하는 기능에 머물러야 한다.[26] 반면 기존 법질서가 보호법익이나 하류의무를 정하고 있을 뿐 상류 공급자에게 동일한 의무가 직접 적용된다고 보기 어려운 경우에는, 별도의 모델층 의무와 그 적용대상·행위유형·법적 효과를 법률이 직접 정하여야 한다. 기존 법질서가 의무화하거나 금지하지 않은 일반적 가치·응답방침은 법정 기준선에 포함될 수 없다.

모델층 평가는 개별 사건의 위법판단과도 구별된다. 특정 모델판·배포구성에서 법적으로 중요한 실패행동의 반복성과 노출경로를 예방적으로 평가할 수 있지만, 그러한 실패의 발견이 곧 개별법상 위법의 성립을 의미하지는 않는다. 각 법률이 요구하는 행위주체·행위태양·귀책·인과관계 등의 요건은 별도로 판단하여야 한다. 반대로 아직 개별 위법사건이 발생하지 않았다는 이유만으로 반복적으로 확인되는 중대한 위험경로의 평가가 배제되는 것도 아니다.

(2) 보호영역과 한계

모델층의 법정 최소선은 기존 법질서가 보호하는 법익과 명시적으로 신설된 모델층 의무에 한정되어야 한다. 다만 보호법익이 기존 법질서에 존재한다는 사실과 범용모델 공급자에게 동일한 모델층 의무가 이미 성립한다는 것은 구별되어야 한다. 이를 구분하면 다음과 같다.

〈표 2〉 법정 위해·권리 기준선의 보호영역과 모델층 평가의 한계

보호영역·위험유형	모델층 평가의 대상	한계	법적 출처·모델층 의무의 상태
생명·신체	중대한 위해능력과 현실적인 노출경로·행위가능성의 결합	추상적 능력이나 불쾌한 응답만으로 부적합 인정 금지	생명·신체의 보호법익 자체는 기존 법질서에 존재하나, 범용모델 공급자에게 독립적인 예방의무를 부과하려면 별도의 법적 근거가 필요

26) AI기본법상 사업자 의무와 다른 법영역의 책임판단을 구별하면서도 전자를 후자의 외부적 준거로 활용할 수 있다고 보는 논의로 안정빈, 앞의 논문(주 20), 441-444면. 다만 위 논문은 형사상 주의의무·보증인지위의 문제를 다루는 것이므로, 본 논문이 제안하는 모델층 공법의무나 행동보증의 직접적인 근거로 원용하는 것은 아니다.

사이버·생물학적 악용	법률상 금지된 중대한 위해행위의 실행·실질적 지원 경로	일반적인 지식·교육·연구정보의 제공까지 확대 금지	개별 금지규범이 공급자의 구체적 행위에 직접 적용되는 범위에서는 기존법 적용. 그 밖의 일반적 모델층 예방의무는 별도의 법률상 근거 필요
개인정보·비밀	무단 취득·추출·전송·누설 등 법적으로 문제되는 행동경로	적법한 처리와 권한 있는 이용은 제외하고 개별법상 위법성은 별도 판단	개인정보보호법 등 개별법이 공급자의 행위에 직접 적용되는 범위에서는 기존법 적용. 독립적인 모델층 의무는 별도 근거 필요
시스템 상태에 관한 중대한 허위표현	실제 권한·접근·도구실행·검증상태 등 객관적으로 확인 가능한 자기상태의 중대한 오표시	일반적 사실오류·논쟁적 견해·가치판단은 제외	기존 표시·거래법의 요건을 충족하는 범위에서는 기존법 적용. 범용모델 일반에 자기상태 표시의무를 부과하려면 신설 법률 필요
승인 없는 중대한 외부행위	법률이 인간의 결정·승인을 요구하는 행위의 무승인 실행경로	독립적인 법률상 승인요건이 없는 일반행위까지 확대 금지	인간의 승인·결정을 요구하는 개별 법률이 직접 적용되는 범위에서만 기존의무 존재. 일반적인 인간승인의무는 별도 입법 없이는 도출되지 않음
평등·차별 금지	현행법이 금지하는 차별이나 법적으로 보장된 접근의 체계적 배제	일반적인 응답평등의무를 새로 창설하지 않음	현행 차별금지·접근보장 법제가 공급자 또는 해당 이용관계에 적용되는 범위에서는 기존법 적용. 일반적인 모델층 응답평등의무는 별도 법적 근거 필요

특히 시스템 상태의 허위표현은 일반적인 환각과 구별되어야 한다. 문제되는 것은 모델이 세계에 관한 사실을 틀리게 말하는 경우 전반이 아니라, 자신의 실제 권한·접근·도구실행·검증상태처럼 객관적으로 확인 가능한 자기상태를 중대하게 잘못 표시하는 경우이다. 기존 표시·거래법이 직접 적용되지 않는 범용모델 일반에 별도의 의무를 부과하려면 법률이 그 대상과 중대성을 정하여야 한다. 과잉거절 역시 그 자체로 법정 최소선이 되는 것은 아니며, 독립적인 차별금지·접근보장 법제가 보호하는 권리가 있는 경우에만 문제된다.

(3) 법률유보와 사전평가의 한계

법정 위해·권리 기준선의 부적합에 공급제한이나 출시 전 적합결정과 같은 시장효과를 부여하려면 엄격한 법적 근거가 필요하다. 법률은 적용대상, 보호법익과 핵심 실패유형, 중대한 부적합의 기본요건, 자료접근의 범위, 가능한 시장효과와 불복절차 등 국가개입의 기본사항을 정하여야 한다.[27)]

(4) 사전평가와 사전검열금지원칙

강화대상에 대하여 국내 제공 전에 적합결정을 받도록 하는 경우에는 헌법 제21조 제2항의 사전검열금지원칙과의 관계를 별도로 검토하여야 한다. 헌법재판소는 사전검열에 해당하는 경우 일반적 법률유보나 목적의 정당성으로 이를 정당화할 수 없다고 보아 왔으므로, 출시 전 적합결정이 검열에 해당하는지는 비례성 심사에 앞서 판단하여야 한다.[28)]

헌법재판소는 검열을 행정권이 표현의 발표 이전에 그 내용을 심사하여 발표 여부를 통제하는 제도로 파악하고, 표현물의 제출의무, 행정권에 의한 사전심사, 심사를 거치지 않은 표현의 금지 및 이를 관철할 강제수단의 존재 등을 주요 판단요소로 제시하였다. 상업광고 역시 표현의 자유의 보호대상이므로 안전이나 소비자보호라는 규제목적만으로 사전검열금지원칙의 적용을 피할 수 없다.[29)]

본 논문의 적합결정이 사전검열과 구별될 수 있는지는 심사객체가 개별 표현물이 아니라 시스템이라는 사정만으로 결정되지 않는다. 시험응답의 의미내용을 행정기관이 심사하고 그 결과에 국내 제공 여부를 결부한다면, 장래의 개별 응답이 아직 존재하지 않는다는 이유만으로 검열금지원칙의 적용 가능성을 배제할 수 없다. 따라서 심사대상·기준·절차와 시장접근에 미치는 효과를 함께 살펴야

---

27) 헌재 2012. 2. 23. 2009헌마318 결정; 헌재 2025. 6. 27. 2023헌바358 결정; 헌재 2016. 3. 31. 2014헌바382 결정; 헌재 2011. 2. 24. 2009헌바13 결정.

28) 헌재 1996. 10. 4. 93헌가13등 결정; 헌재 2015. 12. 23. 2015헌바75 결정.

29) 헌재 1996. 10. 4. 93헌가13등 결정; 헌재 1996. 10. 31. 94헌가6 결정; 헌재 2008. 6. 26. 2005헌마506 결정; 헌재 2015. 12. 23. 2015헌바75 결정.

한다.[30]

그 구별은 심사항목의 성질에서 특히 중요하다. 법률이 특정한 외부행위에서 필요한 승인이나 도구권한의 준수 여부, 객관적으로 확인 가능한 시스템 상태와 같이 표현내용과 직접 구별되는 기능적 요건을 평가하는 경우에는 특정 견해나 정보의 발표 자체를 승인하는 경우와 구별될 여지가 크다. 반면 특정한 정치적·도덕적 견해의 표현 또는 거절 여부나 논쟁적인 사실관계에 관한 국가의 정답을 출시조건으로 삼는다면, 이를 법정 최소선이나 시스템 평가라고 부르는 것만으로 표현내용의 사전승인 문제를 피할 수 없다.

허위표현·차별·권리침해와 같이 응답의 의미내용에 대한 해석이 불가피한 평가항목은 양자의 경계에 놓일 수 있다. 이 경우 단순히 의미내용을 본다는 이유만으로 곧 검열이라고 단정하거나, 반대로 시스템 평가라는 이유만으로 검열성을 부정하여서는 안 된다. 특정 표현의 발표를 행정적 승인에 종속시키는 것인지, 아니면 독립적인 법정요건에 따라 권리침해와 직접 관련되는 기능·권한·배포조건을 평가하는 것인지를 구체적으로 판단하여야 한다. 개별 항목이 사전검열에 해당한다면 그 항목은 출시 전 적합결정의 기준에서 제외하고, 헌법상 허용되는 사후규율이나 기능·권한에 대한 통제로 다시 구성하여야 한다. 따라서 본 논문이 제안하는 것은 사전평가 일반의 합헌성이 아니라, 검열에 해당하지 않는 심사항목과 효과에 한정된 예외적인 사전관문이다.[31]

이러한 개별 심사항목의 통제를 전제로 적합결정은 특정 표현물의 발표허가와 구별되는 확인절차로 구성될 여지가 있다. 표현물의 상영 여부를 종국적으로 결정하는 허가와 등급심사를 구별한 판례도 심사라는 명칭보다 대상·기준·효과를 검토하여야 함을 보여 주는 범위에서 참고할 수 있다. 이를 AI 적합결정과 등급심사의 동일성이나 AI 사전평가 일반의 합헌성을 뒷받침하는 직접 근거로 삼을 수는 없다.[32] 사전검열에 해당하지 않는 경우에도 모델의 제공 제한은 다수

30) 헌재 2008. 6. 26. 2005헌마506 결정; 헌재 2015. 12. 23. 2015헌바75 결정.

31) 헌재 2008. 6. 26. 2005헌마506 결정; 헌재 2015. 12. 23. 2015헌바75 결정; 앞의 2.다. 참조.

32) 앞의 결정.

이용자의 표현 생성·전달과 사업자의 활동에 영향을 미친다. 그러므로 적용대상과 심사항목을 한정하고 분리 가능한 기능·권한의 통제를 우선하는 등 비례성과 침해최소성을 별도로 심사하여야 한다.

(5) 사전관문의 비례성과 기본·강화대상의 구별

출시 전 적합결정이 사전검열에 해당하지 않는다고 하더라도 모든 범용모델에 일반적인 사전심사를 둘 수 있는 것은 아니다. 국내 제공을 적합결정에 결부하는 것은 강한 사전규율이므로, 사후적 시정만으로 중대한 법익침해를 충분히 회복하기 어려운 경우에 한하여 정당화되어야 한다. 이에 본 논문은 행동보증의 일반적인 적용대상을 '기본대상'으로 하고, 그 가운데 별도의 법정요건에 따라 출시 전 적합결정이 요구되는 대상을 '강화대상'으로 구분하는 이원적 구조를 제안한다. 기본대상에는 명세판·모델판·배포구성의 등록·변경추적, 대외적 행동주장의 정확성 및 사후감독을 중심으로 한 행동보증을 적용하고, 강화대상에 한하여 법정 위해·권리 기준선에 관한 출시 전 적합결정을 추가한다. 본 논문에서 헌법적 검토는 국내 기본권 주체에게 적용되는 경우를 기준으로 하며, 외국법인 자체의 기본권 주체성 문제는 별도로 다루지 않는다.

강화대상 지정의 중심기준은 위험의 크기 그 자체보다 사후구제의 불충분성이다. 생명·신체에 대한 회복하기 어려운 침해, 높은 자율성·도구권한에 따른 신속하고 비가역적인 외부행위, 동일한 상류 실패의 다수 하류서비스에 대한 단기간 전파와 같이 사후시정만으로 통제하기 어려운 경우에는 사전적 확인의 필요성이 커질 수 있다. 이용자 수나 시장점유율, 현행 인공지능기본법 제32조의 적용대상이라는 사실은 독립적인 지정요건이 될 수 없고 위험의 노출범위나 별도 법정요건 판단의 자료로만 활용되어야 한다. 제32조에 따른 위험 식별·평가·완화 과정에서 확보된 자료도 필요한 범위에서 재사용할 수 있으나, 강화대상 지정은 독립된 법정요건에 따라 이루어져야 하며 그 요건사실은 행정청이 증명하여

야 한다.[33]

강화대상으로 적법하게 지정된 경우 최초 제공 전 적합결정은 법률이 정한 시장진입요건이므로 필요한 사항이 확인되지 않아 적합결정을 얻지 못한 범위에서는 원칙적으로 제공할 수 있다. 다만 이는 사전관문의 요건이 충족되지 않았다는 의미이지 그 자체로 법정 기준선에 대한 중대한 부적합이 증명되었다는 의미는 아니다. 반대로 이미 적합결정을 받아 제공되고 있는 모델에서는 자료보완의 필요나 평가의 현재성 미확인만으로 기존 결정의 효력이 자동으로 정지되지 않는다. 이 경우에는 영향을 받은 평가항목을 특정하여 보완·재평가하고 보증상태에 그 현재성 여부를 반영하여야 하며, 법률이 사전에 정한 중요변경으로 기존 적합결정의 대상범위를 벗어난 경우에 한하여 그 변경된 범위에 대한 별도의 심사를 요구할 수 있다.

강화대상의 평가와 조치도 필요한 범위에 한정되어야 한다. 평가대상은 법률이 미리 특정한 중대한 위해·권리 실패유형과 이에 직접 관련되는 기능·권한·배포조건으로 제한하고, 부적합이 확인된 경우에도 도구권한·기능·지역·언어·이용자범위 등 위험을 발생시키는 부분의 제한을 우선하여야 한다. 그것만으로 위험을 합리적으로 통제하기 어려운 경우에 한하여 기간부 공급제한과 같은 더 강한 조치를 검토할 수 있다.[34]

4. 규범번역권력과 국가의 가치내용 승인 금지

범용모델 공급자가 행사하는 권력은 사적인 행동규칙을 작성하는 데 그치지 않는다. 사업자는 모델이 따를 목적·원칙과 지시의 우선순위, 충돌하는 요구의 조정방식을 선택하고 이를 학습·사후정렬·상위지시·분류기·도구권한과 제품설정

33) 「인공지능 발전과 신뢰 기반 조성 등에 관한 기본법」 제32조; 같은 법 시행령 제24조. 시행령 제24조 제1항은 학습에 사용된 누적연산량이 10^{26}부동소수점연산 이상일 것, 최첨단 인공지능기술을 적용하여 구성·운영될 것 및 사람의 생명·신체의 안전과 기본권에 광범위하고 중대한 영향을 미칠 우려가 있을 것을 모두 요구한다.

34) 뒤의 제32조의9 제3항 참조.

등을 통하여 실제 행동성향으로 구현한다. 또한 배포 이후에도 그 구현방식을 변경할 수 있고, 하나의 범용모델이 복수의 하류서비스에 공급되는 경우 그 결과도 여러 서비스에 공통적으로 전파될 수 있다. 본 논문은 이러한 사실상의 지배가능성을 포착하기 위하여 '규범번역권력(norm-translation power)'이라는 분석개념을 제안한다. 여기서 규범번역권력이란 추상적 규범을 기술적·조직적 수단을 통하여 범용모델의 행동으로 구현하고, 그 구현상태를 변경·배포할 수 있는 사실상의 지배가능성을 말한다.

규범번역권력은 사적 질서나 규제된 자율규제에 관한 기존 논의를 대체하거나, 사적 규범형성 또는 기술적 정렬·구현에 관한 현상을 하나의 개념으로 재명명하려는 것이 아니다.[35] 여기서 '번역'은 이미 선택된 추상적 규범이 학습·사후정렬·상위지시와 배포구성 등의 기술적·조직적 매개를 거쳐 특정한 모델상태의 행동으로 구체화되는 변환과정을 가리킨다. 동일한 자연어 규범도 어떠한 구현수단과 모델판·배포구성이 결합되는지에 따라 실제 행동이 달라질 수 있다는 점에서, 규범과 행동의 관계는 규범내용의 단순한 집행이나 일대일 대응으로 환원되지 않는다. 또한 '권력'은 공급자에게 국가의 입법권과 같은 규칙제정권이 있음을 의미하는 것이 아니라, 공급자가 이러한 번역의 수단과 방식을 선택하고 배포 이후에도 그 구현상태를 변경하며, 하나의 상류모델을 통하여 그 결과를 복수의 하류서비스에 공통적으로 전파할 수 있다는 사실상의 지배가능성을 뜻한다. 따라서 규범번역권력은 규범선택–행동으로의 기술적 번역–변경·일대다 배포가 하나의 공급자에게 결합된 지배구조를 공법적 분석대상으로 특정하기 위한 개념이다.

이 권력을 공법적으로 통제한다고 하여 국가가 민간 행동규범의 가치적 우열을 판단하여서는 안 된다. 국가는 법률을 통하여 위해·권리의 최소선을 정할 수 있지만, 특정 사업자가 채택한 도움성·응답과 거절방침·인격·문체나 가치조정 방식을 공적으로 승인하는 것은 별개의 문제이다.[36] 국가가 민간의 자율기준을 법

35) 이동진, 앞의 논문(주 23), 158-166면; 이효진, "규제된 자율규제 형태로서 인공지능 표준(AI Standards)의 규범적 쟁점과 과제", 『법과 기업 연구』 제15권 제2호, 2025, 60-65면.

36) Gilad Abiri, "Public Constitutional AI," 59 Georgia Law Review 601 (2025), pp.

정 최소선으로 흡수하거나 반대로 법정 최소선을 근거로 하나의 모범적인 행동 헌장을 요구하면 사적 규범과 공적 최소선의 경계가 무너진다.

따라서 규범번역권력에 대한 통제는 규범원천을 분리하여야 한다. 대외적 행동주장의 정확성규율에서는 공급자가 공식적으로 제시한 행동특성과 실제 모델 행동 사이의 대응관계를 확인하되 그 가치내용 자체를 승인하지 않는다. 법정 위해·권리 기준선에서는 그러한 공표와 독립하여 법률이 정한 최소선을 적용하되, 이를 근거로 법률 밖의 가치·진실·응답방침까지 국가기준으로 확장하지 않는다. 공급자는 서로 다른 행동규범을 선택할 수 있고, 국가는 그 선택 자체가 아니라 대외적 행동주장의 정확성과 독립적인 법정 최소선의 충족을 서로 다른 근거에서 판단하여야 한다.[37]

이러한 구조 아래에서는 법률이 정한 최소조건과 평가절차를 충족하는 범위에서 복수의 민간 행동규범과 규범번역방식이 병존할 수 있다.[38] 이른바 '규율된 다원성'은 새로운 헌법원리를 뜻하는 것이 아니라, 국가가 어느 'AI 헌법'이 더 옳은지를 결정하지 않으면서도 대외적 행동주장의 정확성과 독립적인 법정 한계를 통제할 수 있음을 나타내는 설명개념이다.

5. 공법적 행동보증의 법적 성질

공법적 행동보증[39]은 민간의 행동명세 자체를 국가가 인증하거나 모델 전체의

641, 659.

37) 국가가 인공지능의 정치적·가치적 내용에 일정한 방향을 요구하는 제도는 적용영역과 법적 성격이 서로 다르므로 국내 일반시장 규율의 직접적인 비교모형으로 사용할 수 없다. 다만 객관적 위해·행동상태의 규율과 국가가 선호하는 가치·표현내용의 요구 사이의 경계가 문제될 수 있음을 보여 주는 참고사례로 볼 수 있다. Executive Order No. 14319, "Preventing Woke AI in the Federal Government" (July 23, 2025); Office of Management and Budget, Memorandum M-26-04, "Increasing Public Trust in Artificial Intelligence Through Unbiased AI Principles" (Dec. 11, 2025).

38) Simon Goldstein & Peter N. Salib, A Thousand AI Constitutions(2026), pp. 5-12.

39) 여기서 '보증'은 민법상 보증채무나 특정 결과의 실현을 국가가 보장한다는 의미의 guarantee가 아니라, 특정한 주장과 평가증거를 일정한 대상·범위·시점에 결부하

일반적인 안전성을 보증하는 제도가 아니며, 이는 특정한 모델판·배포구성에 관한 평가의 근거와 효력을 객체·범위·시점별로 특정하고 관리하는 제도적 구성이다. 그 안에서 대외적으로 제시된 행동주장에 대해서는 공표된 행동특성과 실제 행동 사이의 대응관계를 확인하고, 법정 위해·권리 기준선에 대해서는 그 공표와 독립된 법률상 의무의 충족 여부를 판단한다.

이 구조에서 기술적 시험·평가결과는 법적 판단을 위한 증거이고, 보증상태는 각 평가항목에 관하여 무엇이 어느 객체·범위·시점에서 현재 확인되어 있는지를 나타내는 상태정보이다. 따라서 보증상태는 일반적인 공급자격이나 시장접근결정이 아니며, 강화대상의 국내 제공 전에 별도로 요구되는 적합결정과 구별된다. 적합결정의 효력을 제한하거나 변경하려면 독립적인 법률상 요건과 절차가 필요하므로, 특정 평가항목의 현재성을 확인할 수 없게 되었다는 사정이나 보증상태의 변경만으로 기존 적합결정의 효력이 당연히 정지·변경되거나 소멸하는 것은 아니다. 결국 '확인할 수 없음'과 '위반이 확인됨', 평가정보의 변경과 시장접근에 관한 법적 결정의 변경은 각각 구별되어야 한다.[40]

여 그 신뢰가능성을 확인하는 assurance의 의미에 가깝다. Marie Davidsen Buhl et al., 앞의 논문(주 17), pp. 4-7; Arthur Goemans et al., "Safety Case Template for Frontier AI: A Cyber Inability Argument," arXiv:2411.08088 (2024), pp. 3-6; European Union Agency for Cybersecurity, Guidelines on Assurance Continuity—Practical Change Scenarios for Certified ICT Products, version 1 (Dec. 10, 2025), pp. 14-19.

40) UK AI Safety Institute, "Approach to Evaluations" (2024); National Institute of Standards and Technology, Artificial Intelligence Risk Management Framework (AI RMF 1.0), NIST AI 100-1 (2023), pp. 20-27; ISO/IEC 42001:2023, Information Technology—Artificial Intelligence—Management System; ISO/IEC 42006:2025, Requirements for Bodies Providing Audit and Certification of Artificial Intelligence Management Systems.

Ⅳ. 공법적 행동보증의 법적 효과와 입법모형

1. 효과분리원칙

공법적 행동보증에서 확인되는 문제를 하나의 '부적합'으로 묶어 동일한 효과에 연결하여서는 안 된다. 대외적 행동주장의 불일치, 법정 위해·권리 기준선의 중대한 부적합, 평가객체의 특정성·현재성 결여 및 절차의무 위반은 각각 보호목적·증명대상·법적 근거가 다르므로 직접적인 효과도 분리되어야 한다. 특히 보증상태는 이러한 판단과 별개의 제재나 공급자격이 아니라, 각 평가항목에 관하여 현재 무엇이 확인되어 있는지를 표시하는 상태정보이므로 그 내용의 갱신과 시장접근에 관한 법적 효과를 구별하여야 한다.

법적 사유
직접적인 효과
직접 연결하여서는 안 되는 효과
대외적 행동주장의 중요한 불일치
정정·삭제, 불일치 공개, 행동주장 범위조정, 재평가 및 해당 상태정보의 갱신
그 불일치만을 이유로 한 공급·기능 제한 또는 기존 적합결정의 효력변경
법정 위해·권리 기준선의 중대한 부적합
위험에 비례한 기능·권한·배포범위 또는 기간부 공급제한, 해당 부적합 상태의 표시
위험과 무관한 포괄적 공급금지
평가객체의 특정성·현재성 결여
보완, 재평가, 평가범위 조정, '현재성 미확인' 또는 '재평가 필요'의 표시
법정 최소선 위반의 의제 또는 그 사유만을 근거로 한 적합결정의 효력변경
중대한 절차의무 위반

보완·협력 요구, 영향을 받은 평가항목에 대한 확인곤란·현재성 미확인 표시

절차위반만을 근거로 한 실체적 부적합 인정, 공급·기능 제한 또는 기존 적합결정의 효력변경

〈표 3〉 행동보증의 판단사유와 법적 효과의 분리

법적 사유	직접적인 효과	직접 연결하여서는 안 되는 효과
대외적 행동주장의 중요한 불일치	정정·삭제, 불일치 공개, 행동주장 범위조정, 재평가 및 해당 상태정보의 갱신	그 불일치만을 이유로 한 공급·기능 제한 또는 기존 적합결정의 효력변경
법정 위해·권리 기준선의 중대한 부적합	위험에 비례한 기능·권한·배포범위 또는 기간부 공급제한, 해당 부적합 상태의 표시	위험과 무관한 포괄적 공급금지
평가객체의 특정성·현재성 결여	보완, 재평가, 평가범위 조정, '현재성 미확인' 또는 '재평가 필요'의 표시	법정 최소선 위반의 의제 또는 그 사유만을 근거로 한 적합결정의 효력변경
중대한 절차의무 위반	보완·협력 요구, 영향을 받은 평가항목에 대한 확인곤란·현재성 미확인 표시	절차위반만을 근거로 한 실체적 부적합 인정, 공급·기능 제한 또는 기존 적합결정의 효력변경

금전제재도 독립된 법정의무와 제재근거가 있는 경우에만 그 위반에 상응하여 부과할 수 있고, 행동주장의 불일치나 사적 행동규범의 내용만으로 과태료·과징금의 근거를 삼아서는 안 된다.

여러 사유가 함께 존재하더라도 한 사유의 효과를 다른 사유에 전용할 수 없다. 특히 법정 위해·권리 기준선의 중대한 부적합을 이유로 시장접근을 제한하려면 행정청이 이를 독립적으로 증명하여야 하며, 자료부족·협력거부 또는 평가의 현재성 상실로 대신할 수 없다. 보증상태의 변경 역시 새로운 평가결과나 확인가능성의 변화를 표시하는 것일 뿐, 그것만으로 기존 적합결정의 효력을 정지·변경하거나 소멸시키는 근거가 될 수 없다. 처분의 사실적·법적 사유와 그 효과의 범위도 특정되어야 한다. 이는 효과분리원칙이 현행 행정법에서 직접 도출된다는 뜻은 아니지만 비례원칙, 부당결부금지원칙, 이유제시의무 및 처분사유 추가·변

경 제한 법리와 같은 방향에 있다.[41]

효과분리는 서로 다른 규범원천을 법적 효과의 단계에서도 유지하기 위한 원칙이다. 행동주장의 불일치를 시장제한과 직접 연결하면 사적 규범이 공법상 최소기준으로 전환되고, 절차위반이나 확인불능을 실체적 위해와 동일하게 취급하면 입증책임과 법률유보가 우회된다. 따라서 각 사유에는 그 근거에 상응하는 판단·표시·처분만을 결부하여야 하며, 특히 평가정보의 변경을 시장접근에 관한 행정결정의 변경과 동일시하여서는 안 된다.

2. 「제32조의9 행동보증에 관한 조치」 입법모형

효과분리원칙을 입법화하려면 대외적 행동주장의 불일치, 법정 위해·권리 기준선의 중대한 부적합, 평가객체의 특정성·현재성 결여 및 절차의무 위반을 서로 다른 처분사유와 효과에 연결하여야 한다. 이하의 조치조항은 행동보증제도의 모든 의무조항을 완결적으로 제시하려는 것이 아니라, 앞에서 도출한 효과분리원칙이 입법상 어떠한 형태로 구현될 수 있는지를 예시하기 위한 것이다. 따라서 이 조항은 별도의 선행규정에서 행동보증의 적용대상과 명세판·모델판·배포구성의 특정, 대외적 행동주장의 등록, 중요변경의 보고와 재평가, 평가에 필요한 자료제출·검사협력 및 공개등록부의 관리가 정하여져 있음을 전제로 한다. 제32조의9에서 인용하는 제32조의4 역시 이러한 선행규정 가운데 법정 위해·권리 기준선의 적용대상과 판단기준을 정하는 조항을 가정한 것이다.

여기서 기술적 평가결과는 법적 판단의 증거이고, 보증상태는 각 평가항목에 관하여 무엇이 어느 객체·범위·시점에서 현재 확인되어 있는지를 나타내는 상태정보이다. 보증상태의 변경은 새로운 사실이나 평가결과에 맞추어 그 정보의 내용을 갱신하는 것이며, 그 자체로 시장접근에 관한 권리를 부여하거나 박탈하는 처분을 의미하지 않는다. 강화대상의 출시 전 적합결정은 별도의 선행규정이 정

41) 「행정기본법」 제10조·제13조; 「행정절차법」 제23조; 대법원 2024. 11. 28. 선고 2023두61349 판결; 대법원 2021. 7. 29. 선고 2021두34756 판결.

한 요건과 절차에 따라 시장접근효를 갖는 독립적인 행정적 결정으로 구성한다. 따라서 보증상태의 변경만으로 기존 적합결정의 효력을 우회하여 정지·변경하거나 소멸시켜서는 아니 된다.

또한 출시 전 적합결정은 모든 범용모델에 일반적으로 요구되는 절차가 아니라, 법률이 정한 중대한 위해가 사후구제로 충분히 회복되기 어렵고 사전적 시장관문이 별도로 정당화되는 경우에 한하여 둘 수 있는 예외적인 절차를 전제로 한다. 본 논문은 이러한 선행의무군 전체를 조문화하기보다, 그 위반·확인불능 또는 실체적 부적합에 어떠한 효과를 연결할 것인지에 한정하여 조치조항을 제시한다. 제8항의 긴급조치에 둔 30일은 기본권 제한의 강도와 자동실효의 필요성을 나타내기 위한 예시적 상한이다.

제32조의9(행동보증에 관한 조치)

① 과학기술정보통신부장관은 이 법에 따라 등록된 대외적 행동주장 중 특정한 입력유형이나 상황에서 관찰 가능한 행동으로 확인할 수 있는 것과 실제 모델행동 사이에 중요한 불일치가 확인된 경우 공급자에게 그 주장의 정정 또는 삭제, 불일치 사실과 영향범위의 공개, 행동주장의 적용범위 조정 또는 필요한 재평가를 명할 수 있다.

② 제1항의 불일치만을 이유로 해당 모델의 국내 공급, 기능·언어·지역·이용자범위를 제한하거나 기존 적합결정의 효력을 정지·변경하거나 소멸시켜서는 아니 된다. 다만 보증상태에는 확인된 불일치와 그 영향범위를 반영하여야 한다. 공급자의 대외적 행동주장은 제32조의4에 따른 법정 위해·권리 기준선의 내용이나 판정기준을 창설하거나 변경하지 아니한다.

③ 장관은 실제 모델행동이 제32조의4에 따른 법정 위해·권리 기준선에 중대하게 부적합하다고 객관적인 증거에 의하여 확인한 경우 위해의 심각도와 발생가능성, 실제 노출범위 및 회복가능성을 고려하여 기능·권한 또는 배포범위의 제한이나 위험방지에 필요한 범위의 기간부 공급제한을 명할 수 있다. 조치는 확인된 위험을 방지하기 위한 최소한의 범위에 한정하여야 하며, 해당 보증상태에는 법정 기준선의 부적합이 확인되었다는 사실과 그 범위를 반영하여야 한다.

④ 제3항에 따른 중대한 부적합의 존재에 대한 입증책임은 장관에게 있다. 장관은 주요 평가대상·판정기준·실패기준·표본선정방식 및 재현방법을 평가 착수 전에 확정·기록하여야 하며, 평가결과를 확인한 후 공급자에게 불리하도록 변경하여서는 아니 된다.[42)]

⑤ 공급자가 등록·변경보고·자료제출·검사협력 등 이 법에 따른 절차의무를 중대하게 위반하여 현재의 행동보증에 대한 감독 또는 **평가상태의 현재성** 확인이 현저히 곤란하게 된 경우 장관은 필요한 자료의 보완이나 협력을 명하고, 영향을 받은 평가항목과 범위의 보증상태에 현재성의 확인이 곤란하다는 사실을 표시할 수 있다. 위반사유가 해소되고 현재성이 다시 확인된 때에는 그 결과에 맞게 보증상태를 갱신하여야 한다. 이 항의 조치로 제3항의 중대한 부적합에 대한 입증을 대신하거나, 그 사유만으로 모델의 공급·기능을 제한하거나 기존 적합결정의 효력을 변경하여서는 아니 된다.

⑥ 제5항에 따른 보완 또는 협력의 기회를 부여하였음에도 그 사유가 해소되지 아니하여 특정 평가항목의 현재 유효성을 합리적으로 확인할 수 없는 경우 장관은 확인할 수 없는 범위의 보증상태를 '현재 유효성 미확인'으로 갱신할 수 있다. 이 경우 해당 판본의 등록내용, 종전 평가결과와 보증상태 및 변경이력은 보존하여야 하며, 제5항 또는 이 항의 사유만으로 대외적 행동주장에 관한 등록기록 자체를 말소하거나 기존 적합결정의 효력을 정지·변경하거나 소멸시켜서는 아니 된다.

⑦ 명세판·모델판·배포구성 또는 평가범위의 특정이 불충분하거나 변경으로 종전 평가의 현재성을 확인하기 어려운 경우 장관은 자료의 보완, 평가범위의 조정 또는 재평가를 요구하고 그 동안 영향을 받은 평가항목의 보증상태에 '재평가 필요' 또는 '현재성 미확인'임을 표시할 수 있다. 이러한 특정성 또는 현재성의 결여만으로 제32조의4에 따른 부적합을 인정하여서는 아니 된다. 정당한 이유 없이 이 항의 요구에 응하지 아니하여 감독 또는 **평가상태의 현재성** 확인이 현저히 곤란하게 된 경우에는 제5항을 적용할 수 있다.

⑧ 생명·신체에 대한 중대한 위해가 급박하고 실제 노출가능성이 있으며 통

42) 여기서 입증책임은 처분요건인 중대한 부적합을 행정청이 확인·증명하여야 한다는 의미이며, 행정소송상 입증책임의 일반법리를 변경하려는 것은 아니다. 공급자의 자기평가나 제출자료를 사용하는 경우에도 그 신뢰성과 관련성은 독립적으로 검토되어야 한다.

상적인 절차로 그 방지가 현저히 곤란한 경우 장관은 제3항에 따른 조치 중 필요한 최소한의 조치를 30일의 범위에서 잠정적으로 명할 수 있다. 장관은 지체 없이 본안평가와 필요한 검증 및 공급자의 의견제출 절차를 진행하여야 하며, 그 기간 안에 제3항의 요건이 확인되지 아니하면 잠정조치는 효력을 잃는다. 보증상태에는 잠정조치가 이루어졌다는 사실과 그 법적 근거·범위·기간을 본안의 부적합 판단과 구별하여 표시하여야 한다.

⑨ 조사 또는 재평가가 개시되었다는 사실만으로 기존의 평가항목을 부적합한 것으로 표시하여서는 아니 된다. 공개등록부에서는 대외적 행동주장의 불일치, 법정 위해·권리 기준선의 부적합, 특정성·현재성의 미확인, 절차의무 위반 및 긴급한 잠정조치를 서로 구별하여 표시하여야 한다. 제1항·제3항·제5항부터 제8항까지에 따른 판단이나 조치가 이루어진 경우에는 법적 근거, 대상 판본·배포범위, 해당 평가항목, 판단 또는 조치의 내용·기간 및 주요 이유를 등록부에 표시하여야 한다.

⑩ 장관은 이 조에 따른 불리한 처분을 하려는 경우 처분의 원인이 되는 사실과 법적 근거 및 주요 근거자료를 통지하고 의견제출의 기회를 부여하여야 한다. 처분서에는 평가대상 판본과 배포구성, 주요 시험환경과 실패기준, 제한의 대상·범위·기간, 주요 이유, 해제 또는 재개요건 및 불복방법을 구체적으로 밝혀야 한다.[43]

제1항부터 제4항까지는 공급자의 자기공표와 독립적인 법정 최소선을 구별한다. 행동주장의 불일치는 정정·공개·범위조정 및 재평가의 사유가 되지만, 시장제한은 법정 위해·권리 기준선의 중대한 부적합이 별도로 증명된 경우에만 허용된다. 이때 행정청은 사전에 특정된 평가기준과 객관적 증거에 따라 부적합을 독립적으로 증명하여야 한다. 보증상태는 이러한 판단결과를 반영하는 상태정보이므로, 불일치나 부적합이 확인된 경우 그 내용을 갱신할 수 있을 뿐 그 자체를 독립적인 제재로서 정지·취소하는 것으로 구성하지 않는다.

제5항부터 제9항까지는 절차위반·확인불능·긴급조치를 실체적 부적합과 분

43) 「행정절차법」 제21조부터 제23조까지·제27조 등 참조. 행정조사와 사법적 구제에 관한 일반규율은 각 관계 법률에 따른다.

리한다. 자료제출이나 검사협력의 결여, 판본·배포구성의 특정성 또는 현재성 상실은 해당 평가항목을 '확인곤란', '현재 유효성 미확인' 또는 '재평가 필요'로 표시하고 감독가능성을 회복하기 위한 조치를 정당화할 수 있을 뿐, 그 자체로 법정 최소선 위반을 의제하지 않는다. 따라서 '확인할 수 없음'은 '위반이 확인됨'을 대신할 수 없다. 더 나아가 보증상태의 변경 역시 기존 적합결정의 효력변경을 대신할 수 없다. 긴급조치는 이러한 원칙의 예외가 아니라, 별도의 급박한 위해요건 아래 잠정적으로 허용되는 독립된 조치이며 신속한 본안평가와 의견제출 절차로 전환되어야 한다.

3. 입법모형의 의미와 그 한계

제32조의9의 의미는 모델행동에 관한 여러 문제를 하나의 포괄적 '안전성' 판단으로 통합하지 않고, 각각의 규범적 근거에 상응하는 법적 효과를 결부한다는 데 있다. 대외적 행동주장의 불일치에는 정보정확성에 관한 효과를, 법정 위해·권리 기준선의 중대한 부적합에는 독립적인 법률상 근거에 따른 시장제한을, 특정성·현재성 결여와 절차위반에는 각각 보증상태와 감독가능성에 관한 효과를 부여한다.

이러한 구조는 공급자의 규범번역권력뿐 아니라 이를 감독하는 행정권도 제한한다. 특히 절차위반이나 자료부족으로 현재의 적합성을 확인할 수 없다는 사실을 실체적 부적합의 증거로 전환하지 못하게 함으로써, 시장제한에 필요한 독립적인 법적 근거와 증명을 보존한다. 공법적 행동보증의 핵심은 결국 사적 규범을 국가기준으로 승인하는 데 있지 않고, 특정된 모델상태에 관한 판단의 근거와 효과를 서로 결박하는 데 있다.

실제 제도화에서는 평가대상이 법정 기준선에 관한 것이라면 적용 법조를, 대외적 행동주장의 정확성에 관한 것이라면 검증할 행동주장을 특정하고, 대상 모델판·배포구성과 평가범위, 주요 시험조건·표본선정방식·판정기준 및 불확실성의 취급을 기록하여 평가결과가 어떠한 조건에서 형성되었는지를 확인할 수 있

어야 한다. 주요 실패유형과 판정기준은 평가 전에 특정하여 결과에 맞추어 공급자에게 불리하게 변경하지 못하도록 하되, 평가적응이나 우회를 방지하기 위하여 개별 시험문항까지 모두 사전에 공개할 필요는 없다. 비공개 자료나 시험정보를 처분근거로 사용하는 경우에도 그 범위와 필요성을 한정하고, 공급자가 불리한 판단의 근거와 시험조건을 실질적으로 반박할 수 있는 절차를 보장하여야 한다. 자료접근 역시 공개자료·기존 평가자료와 제한된 시험접근을 우선 활용하고, 학습자료·가중치·소스코드 전부에 대한 일반적 접근권을 전제하여서는 안 된다. 구체적인 표본수·허용오차·심사기간·비용과 전문인력의 규모는 별도의 실증적 검토가 필요하지만, 이러한 기록·사전특정·반박가능성은 공법적 행동보증이 기술적 평가를 법적 판단의 증거로 사용할 수 있기 위한 기본조건이다.[44)]

V. 결론

본 논문은 서비스형 범용모델 공급자가 추상적 규범을 실제 모델행동으로 구현하고 그 구현상태를 변경·배포할 수 있는 사실상의 지배가능성을 포착하기 위하여 '규범번역권력'이라는 분석개념을 제안하였다. 민간의 'AI 헌법'이 공법적으로 중요한 이유는 그 문서에 국가헌법과 유사한 법적 지위가 있기 때문이 아니라, 규범선택과 행동으로의 기술적 번역, 변경과 일대다 배포가 하나의 공급자에게 결합될 수 있기 때문이다.

---

44) National Institute of Standards and Technology, Artificial Intelligence Risk Management Framework (AI RMF 1.0), NIST AI 100-1 (2023), pp. 20-27; UK AI Safety Institute, "Approach to Evaluations" (2024); 「행정조사기본법」 제4조; 「행정절차법」 제20조·제23조.

공법상 평가에서는 문서나 추상적인 모델명 자체보다 평가증거와 판단이 어느 모델상태에 귀속되는지가 중요하다. 대외적 행동주장의 정확성을 판단할 때에는 특정한 명세판–모델판–배포구성에서 공표된 행동특성과 실제 행동 사이의 대응관계를 특정하여야 하고, 법정 위해·권리 기준선에 대해서는 그 공표와 립된 법률상 의무를 적용하여야 한다. 판본결박은 이러한 평가의 증거와 효력을 객체·범위·시점에 한정하고, 유의미한 변경 후 종전 평가를 계속 원용할 수 있는 범위를 다시 확인하게 한다.

현행 인공지능기본법과 표시·거래규율도 위험관리, 자료관리, 실증과 시정 등 관련 기능을 수행할 수 있다. 따라서 본 논문의 문제제기는 규율의 부재를 전제로 하지 않는다. 추가로 검토할 것은 기존 수단으로 확보된 증거가 어느 판본과 행동항목에 관한 것인지, 그리고 모델판이나 배포구성이 변경된 뒤에도 종전 평가가 어느 범위에서 현재성을 유지하는지를 공통적으로 확인할 수 있는가이다. 기존 법률의 적법한 해석과 집행으로 이를 확보할 수 있다면 그 수단을 우선 활용하여야 하며, 새로운 의무나 시장효과를 부과하려면 별도의 법적 근거가 필요하다.

이러한 전제에서 공법적 행동보증은 하나의 포괄적인 안전인증이나 공급허가가 아니라 각 평가항목의 근거와 현재성을 관리하는 제도적 구성으로 이해되어야 한다. 기술적 평가결과는 법적 판단을 위한 증거이고, 보증상태는 무엇이 어느 객체·범위·시점에서 확인되어 있는지를 나타내는 상태정보이며, 강화대상에 대한 적합결정은 독립적인 법률상 요건에 따라 시장접근효를 갖는 별도의 행정적 결정이다. 따라서 행동주장의 불일치, 법정 기준선의 중대한 부적합, 현재성 미확인과 절차위반은 서로 구별되어야 하고, 평가정보의 변경이 곧 기존 적합결정의 효력 변경으로 이어져서도 안 된다. 특히 '확인할 수 없음'은 '위반이 확인됨'을 대신할 수 없다.

결국 규범번역권력에 대한 공법적 통제의 목적은 국가가 어느 민간 행동규범이 더 옳은지를 결정하는 데 있지 않다. 대외적으로 제시된 행동주장의 정확성과 독립적인 법정 최소선을 서로 다른 규범원천에 따라 판단하고, 판본·증거·현재성과 법적 효과를 결박함으로써 공급자의 변경권력과 이를 감독하는 행정권을 함

께 한정하는 데 있다. 구체적인 평가방법·표본·비용·심사기간과 제도의 실증적 효과에는 추가적인 검토가 필요하지만, 이러한 구조적 구별은 민간의 가치다원성을 보존하면서 범용모델의 행동형성·변경에 공적 책임을 부과하기 위한 출발점이 된다.

투 고 일 : 2026. 09. 10
심사종료일 : 2026. 09. 12
게재확정일 : 2026. 09. 20

[참 고 문 헌]

1. 국내문헌

고학수·박도현·이나래, "인공지능 윤리규범과 규제 거버넌스의 현황과 과제", 『경제규제와 법』 제13권 제1호, 2020, 7-36면.

김민규, "직업규제 영역의 인공지능 기능대체와 고위험성 판단기준—직업의 자유 제한 법리에 기초한 기능적 등가성 기준의 제안—", 『법조』 제75권 제2호, 2026, 401-443면.

김민규, "AI는 왜 믿음을 얻는가—AI-Washing, 판단외관, 그리고 AX 시대의 표지신의칙—", 『동아법학』 제112호, 2026, 15-56면

안정빈, "AI기본법상 AI사업자 의무와 형사법상 조직책임—책임구조·의무층위·피해자구제를 중심으로—", 『법학논고』 제94집, 2026, 429-459면.

양나리·신혜린, "의미 없는 대화, 의미 있는 충돌: 조롱형 AI 챗봇과의 말싸움 현상에 대한 문화적 분석", 『비교문화연구』 제77호, 2026, 231-276면.

유성희·서효중, "생성형 AI 플랫폼 거버넌스의 절차적 신뢰: 사적 규범, 정책 드리프트, 시민사회형 알고리즘 감사", 『시민사회와 NGO』 제24권 제1호, 2026, 23-61면.

이동진, "자율규제와 사적 질서", 『법조』 제72권 제4호(통권 제760호), 2023, 145-178면.

이병준·문현지, "생성형 AI와 투명성", 『소비자문제연구』 제56권 제3호, 2025, 163-192면.

이창민, "인공지능에 대한 합헌적 규제 거버넌스론 — '클로드 헌법'에 대한 논평으로부터—", 『법조』 제75권 제2호, 2026, 190-231면.

이효진, "규제된 자율규제 형태로서 인공지능 표준(AI Standards)의 규범적 쟁점과 과제", 『법과 기업 연구』 제15권 제2호, 2025, 57-87면.

2. 국외문헌

Abiri, Gilad, "Public Constitutional AI," 59 Georgia Law Review 601-670 (2025).

Ahmed, Ahmed et al., "SpecEval: Evaluating Model Adherence to Behavior Specifications," arXiv:2509.02464v2 (2025) (preprint).

Bai, Yuntao et al., "Constitutional AI: Harmlessness from AI Feedback," arXiv:2212.08073 (2022) (preprint).

Buhl, Marie Davidsen et al., "Safety Cases for Frontier AI," arXiv:2410.21572 (2024) (preprint).

Goemans, Arthur et al., "Safety Case Template for Frontier AI: A Cyber Inability Argument," arXiv:2411.08088 (2024) (preprint).

Goldstein, Simon & Peter N. Salib, A Thousand AI Constitutions (unpublished manuscript, 2026), https://philarchive.org/archive/GOLATA-3.

Guan, Melody Y. et al., "Deliberative Alignment: Reasoning Enables Safer Language Models," arXiv:2412.16339v2 (2025) (preprint).

Jakkli, Arya, Senthooran Rajamanoharan & Neel Nanda, "How Well Do Models Follow Their Constitutions?," arXiv:2605.24229v1 (2026) (preprint).

Li, Chloe et al., "Model Spec Midtraining: Improving How Alignment Training Generalizes," arXiv:2605.02087v2 (2026) (preprint).

3. 공식문서·표준

Anthropic, Claude's Constitution (Jan. 2026).

Anthropic, "Claude's New Constitution" (Jan. 22, 2026).

Anthropic, Collective Constitutional AI: Aligning a Language Model with Public Input, Policy Memo (2023).

Anthropic, "Model IDs and Versioning" (최종방문 2026. 8. 28.).

European Commission, General-Purpose AI Code of Practice—Transparency Chapter (July 2025).

European Commission, General-Purpose AI Code of Practice—Safety and Security Chapter (July 2025).

European Commission, Guidelines on the Scope of the Obligations for Providers of General-Purpose AI Models under the AI Act, C(2025) 5045 final, Annex (18 July 2025).

European Union Agency for Cybersecurity, Guidelines on Assurance Continuity—Practical Change Scenarios for Certified ICT Products, version 1 (Dec. 10, 2025).

Guo, Alan & Jason Wolfe, "Introducing Model Spec Evals," OpenAI Alignment Research Blog (Mar. 25, 2026).

Regulation (EU) 2024/1689

Cal. Bus. & Prof. Code §§ 22757.12, 22757.15

Executive Order No. 14319, "Preventing Woke AI in the Federal Government" (July 23, 2025).

Office of Management and Budget, Memorandum M-26-04, "Increasing Public Trust in Artificial Intelligence Through Unbiased AI Principles" (Dec. 11, 2025).

ISO/IEC 42001:2023, Information Technology—Artificial Intelligence—Management System.

ISO/IEC 42006:2025, Requirements for Bodies Providing Audit and Certification of Artificial Intelligence Management Systems.

National Institute of Standards and Technology, Artificial Intelligence Risk Management Framework (AI RMF 1.0), NIST AI 100-1 (2023).

OpenAI, Model Spec, version Aug. 18, 2026.

OpenAI, "Inside Our Approach to the Model Spec" (2026).

OpenAI, "API Reference—Backwards Compatibility" (최종방문 2026. 8. 28.).

개인정보보호위원회, "개인정보위, 오픈AI에 과태료 부과 및 개선권고", 2023. 7. 27.

개인정보보호위원회, "개인정보위, 인공지능 친구 '카나나' 서비스 관련 사전적정성 검토 결과 심의·의결", 2025. 3. 13.

개인정보보호위원회, "네이버 검색 인공지능 에이전트 서비스('AI Tab') 사전적정성 검토 결과 의결", 2026. 5. 31.

카카오, "책임 있는 AI 개발을 위한 실천, Kanana-1.5-9.8B 안전성 평가 결과 공개", Tech Ethics 제22호.

UK AI Safety Institute, "Approach to Evaluations" (2024).

■ 국문 초록

민간 AI '헌법'의 행동 구현에 대한 공법적 통제

— 범용모델 공급자의 규범번역권력을 중심으로 —

김 민 규* · 박 상 영** · 남 한 결***

생성형 인공지능의 행동은 법률이나 이용자의 지시만으로 결정되지 않는다. 특히 공급자가 배포 이후에도 모델판 또는 행동에 유의미한 영향을 미치는 배포구성을 통제하는 서비스형 범용모델에서는, 자연어로 정한 목적·원칙·우선순위와 예외가 학습·정렬·상위지시 및 배포구성을 통하여 실제 행동으로 구현되고 그 상태가 계속 변경될 수 있다. 본 논문은 추상적 규범을 기술적·조직적 수단을 통하여 범용모델의 행동으로 구현하고 그 구현상태를 변경·배포할 수 있는 공급자의 사실상 지배가능성을 포착하기 위하여 '규범번역권력'이라는 분석개념을 제안한다.

공법상 핵심문제는 민간의 'AI 헌법'이라는 문서 자체를 승인하는 데 있지 않다. 대외적 행동주장의 정확성을 판단할 때에는 특정한 명세판–모델판–배포구성에서 공표된 행동특성과 실제 행동 사이의 대응관계를 특정하고, 법정 위해·권리 기준선에 대해서는 그러한 공표와 독립된 법률상 의무를 적용하여야 한다. 본 논문은 평가증거와 판단의 객체적·시간적 효력범위를 특정하는 '판본결박'과 행동주장의 불일치·법정 기준선의 중대한 부적합·평가의 특정성 또는 현재성 결여·절차위반에 서로 다른 법적 효과를 결부하는 '효과분리'를 제안한다.

공법적 행동보증은 이러한 구조를 기존 위험관리·실증·시정수단과 결합하여 각 평가항목의 근거·범위·현재성을 관리하는 제도적 구성이다. 여기서 기술적 평가결과

* 김민규 주저자, KAIST 문술미래전략대학원 겸직교수, 변호사
** 박상영 공저자, 서울대학교 일반대학원 법학과 석사과정
*** 남한결 공저자, 부산대학교 공공정책학부

는 법적 판단을 위한 증거이고, 보증상태는 그 판단의 현재 유효범위를 나타내는 상태정보이며, 강화대상의 적합결정은 별도의 법률상 근거를 갖는 시장접근에 관한 행정적 결정으로 구별된다. 이러한 구조는 공급자의 규범번역권력과 이를 감독하는 행정권을 함께 통제하면서도, 국가가 사적 가치내용의 승인자로 확장되는 것을 방지한다.

주제어 : AI 헌법, 규범번역권력, 범용 인공지능모델, 공법적 행동보증, 인공지능 규제

■ Abstract

Public-Law Control of the Behavioral Implementation of Private AI "Constitutions"
— The Norm-Translation Power of General-Purpose AI Model Providers —

Generative AI behavior is shaped not only by law or user instructions but also by privately formulated norms implemented through training, alignment, higher-level instructions, and deployment configurations. This Article focuses primarily on service-based general-purpose AI models whose providers retain control, after deployment, over model versions or deployment configurations that materially affect behavior. To capture the provider's de facto capacity to implement abstract norms as model behavior and to modify and distribute the resulting behavioral state, this Article proposes "norm-translation power" as an analytical concept.

The central public-law issue is not whether the state should endorse a private "AI constitution" as such. For publicly stated behavioral claims, the relevant object of evaluation is the correspondence between the behavioral characteristics represented by the provider and actual behavior within a specified specification

KIM MIN GYU*
PARK SANG YOUNG**
NAM HAN GYEOL***

* Attorney at Law, Adjunct Professor, KAIST Moon Soul Graduate School of Future Strategy
** Master's student, Seoul National Univeristy School of Law
*** Pusan National University of Public Policy

version, model version, and deployment configuration. Statutory harm-and-rights baselines, by contrast, must rest on legal duties that apply independently of such private claims. The Article proposes "version-binding" to limit the object, evidentiary basis, scope, and temporal validity of each evaluation, and an "effect-separation principle" under which claim discrepancies, serious statutory nonconformity, loss of specificity or current validity, and procedural breaches produce distinct legal consequences. Public-law behavioral assurance is conceived as an institutional framework that combines these principles with existing risk-management, substantiation, and corrective mechanisms. Technical evaluation results serve as evidence for legal judgment; assurance status records what has been verified within a specified scope and time; and a pre-market conformity decision for specially designated models, where legally required, constitutes a distinct administrative decision concerning market access. This structure seeks to hold providers accountable for their norm-translation power while preventing the state from converting private behavioral values into substantive public standards.

KeyWord : AI Constitutions; Norm-Translation Power; General-Purpose AI Models; Public-Law Behavioral Assurance; AI Regulation