[논 문] https://doi.org/10.31839/DALR.2026.08.112.15

AI는 왜 믿음을 얻는가

– AI-Washing, 판단외관, 그리고 AX 시대의 표지신의칙 –

김 민 규*

≪차 례≫

Ⅰ. 서론: AI-Washing의 문제 전환
Ⅱ. 혁신표지의 계보와 판단외관의 형성
Ⅲ. AI+전문자격표지와 전문신뢰의 차용
Ⅳ. 표지-실질 정합성 판단과 외관신뢰법리의 접속
Ⅴ. 결론: AX 시대의 표지신의칙

Ⅰ. 서론: AI-Washing의 문제 전환

1. 문제의 제기

오늘날 “AI”라는 표지는 상품과 서비스 전반으로 빠르게 번진다. 스마트폰·PC·가전을 지나 금융·교육·의료·법률·공공서비스까지, AI는 더 이상 한정된 기술 영역 안에 머물지 않는다. AI라는 표지는 이용 맥락에 따라 해당 상품이나 서비스가 더 빠르고 일관되게 자료를 처리하거나 지능적으로 판단할 것이라는 기대를 환기할 수 있다.[1] 국내에서도 AI 능력 과장 표시를 인공

* KAIST 문술미래전략대학원 겸직교수, 변호사

지능기본법·민사법·소비자법의 통합적 관점에서 풀어내려는 시도가 이어진다.[2)]

이런 현상이 통째로 새로운 것은 아니다. 우주 시대의 "우주", 컴퓨터 보급기의 "컴퓨터", 나노기술 유행기의 "나노"와 "은나노", 생명과학 담론의 "바이오"는 모두 기술적 우수성·미래성·과학성·정밀성의 이미지를 상품과 서비스에 얹어 주었다. AI-Washing은 이러한 혁신표지 오용의 역사적 계보 위에 놓여 있다. 그러나 AI 표지는 앞선 혁신표지와 결정적으로 다르다. "컴퓨터"가 주로 자동화와 정확성의 기대를, "나노"가 과학성과 정밀성의 기대를 호출했다면, "AI"는 자율성과 지성을 전제로 하는 판단능력의 기대를 호출한다. AI라는 단어를 접한 이용자는 기계가 더 빨리 움직인다고 기대하는 데서 그치지 않고, 시스템이 자료를 읽고 사안을 분류하고 가능성을 따져 본 뒤 결론을 내놓는다고 받아들인다.

이러한 맥락에서 AI 표지는 단순한 기술표지를 넘어 판단능력에 관한 기대를 환기하는 신뢰표지로 기능할 수 있다. 여기서 AI를 신뢰표지라고 한다고 하여 AI라는 표시가 언제나 이용자의 신뢰를 높인다는 뜻은 아니다. 본고가 주목하는 것은 AI라는 명칭과 그에 결합된 표현·인터페이스가 일정한 지능적 판단이 수행되고 있다는 외관을 형성할 수 있다는 점이다. 이 글은 그러한 외관을 '판단외관'이라 부른다. 다시 말해, 판단외관은 AI 또는 AI 유사 표상 구조가 이용자에게 인간 전문가와 비슷한 판단이 수행되고 있다는 인상을 남기는 상태를 가리킨다.

문제는 그 판단외관이 실제 기능·적용범위·한계·책임구조와 어긋날 때 생긴다. 어떤 서비스가 "AI 변호사"라고 표시되면, 이용자는 그것이 인간 변

---

1) AI 표지가 기술적 정교함과 조직적 정당성을 신호하여 이해관계자의 신뢰와 자원 확보에 활용될 수 있다는 분석으로 Elsayed, N. (2026), pp. 12-13 참조. AI-Washing 표현이 동일 제품의 AI 기능·성능평가와 구매의도를 높이고 정보신뢰는 기만성 인지 전까지 유지될 수 있음을 보인 국내 실증으로 신지원·김은서·이인수·사지연, 「가전제품 표시광고에서의 AI 워싱 표현과 소비자교육이 소비자반응에 미치는 효과: 20대 소비자를 중심으로」, 『소비자정책교육연구』 제22권 제1호, 2026, 62면, 66-67면 참조.

2) 국내에서도 AI-Washing의 민사법적 책임을 인공지능기본법 정의규정과 연계하여 분석한 연구가 본격화되고 있다. 김태형, 「AI 워싱의 민사법적 책임과 대응방안—인공지능기본법 정의규정을 중심으로」, 『민사법의 이론과 실무』 제28권 제3호, 민사법의이론과실무학회, 2025, 127면 및 각주 2 참조.

호사가 아님을 알기에 자격사칭에서 느낄 위화감을 덜 느낀다. 그러나 “변호사”라는 말은 법률문제에 관한 전문적 판단·자격·책임·윤리·징계 가능성에 관한 기대를 함께 끌고 들어온다. “AI”라는 수식어가 위화감을 완화하는 동안, 뒤에 붙은 “변호사”는 제도적 신뢰를 그대로 가져온다. AI-Washing 문제가 “AI가 실제로 쓰였는가”에서 끝나지 않는 이유가 여기에 있다. 실제로 AI가 사용되었더라도 그 기능이 단순 정보검색·자동응답에 머무는데 전문적 판단을 수행하는 것처럼 표시될 수 있고, 반대로 AI가 아니거나 낮은 수준의 자동화 시스템에 가까운데도 AI 표지 덕분에 고도화된 판단능력을 가진 것처럼 보일 수 있다. AI가 법률·의료·금융 등 고위험 영역으로 들어가면서 이 두 방향의 어긋남은 모두 무거워진다.

결국 AI-Washing의 판단은 AI가 실제로 사용되었는지를 확인하는 데서 출발하지만, 그 여부만으로 끝나지 않는다. AI가 실제 사용되었더라도 AI 표지가 형성하는 판단능력·전문성·책임구조에 관한 외관이 실제 기능·범위·한계와 어긋날 수 있기 때문이다. 이 글은 그 어긋남을 AI-Washing이라 부르고, 다음과 같이 정의한다.

<표 1> AI-Washing의 개념 정의

AI-Washing이란, AI 또는 AI 유사 표지가 AI의 존재·수준·기능·성능·전문성·책임구조 등에 관한 외관을 형성하고, 그 외관이 실제 서비스의 실질과 중대하게 어긋남으로써 이용자의 적정한 판단 또는 신뢰를 왜곡하는 현상을 말한다.

경영학·조직론에서는 AI-Washing을 기업이 AI 역량을 실제보다 부풀리거나 표면적으로만 신호화하여 재무·평판상의 이익을 얻으려는 현상으로 풀이하고, 마케팅·브랜딩, 기술역량 과장, 전략적 신호, 거버넌스 차원의 워싱을 그 갈래로 든다.[3] 본고가 이 시각에서 빌려 오려는 것은 분류표 자체가 아니라 한 가지 통찰이다. 외부 표상과 내부 실질이 어긋난다는 점, 곧 신호와 실

3) Elsayed, 앞의 논문, pp. 13-15.

질의 불일치가 문제의 뼈대를 이룬다는 점이다. 그것은 greenwashing 논의와 공유되는 핵심이기도 하다.[4)]

이 글은 AI-Washing을 경영학·조직론, 인간-AI 상호작용 연구 및 법학의 세 가지 관점에서 분석한다. 앞의 두 관점은 AI 표지가 채택되고 이용자의 신뢰와 정보비대칭이 형성되는 메커니즘을 설명하며, 법적 평가는 개별 법규범의 요건에 따라 별도로 이루어진다.

2. 금지의 문제가 아니라 표지신의칙의 문제

AI-Washing을 문제 삼는다고 해서 AI형 서비스나 AX(조직과 서비스 전반을 AI 중심으로 재편하는 인공지능 전환, AI Transformation) 시도 자체를 부정하는 것은 아니다. AI를 이용한 법률정보 정리, 의료정보 탐색, 세무자료 분석, 계약서 초안 작성, 판례 검색, 위험도 분류는 모두 충분히 유용하다. 논의의 초점은 반(反)AI 규제론이 아니라, AI라는 표지가 실제 기능에 맞지 않는 기대를 끌어오는가에 있다. AI-Washing은 AI 자체를 의심하는 문제가 아니라, AI를 부를 때 그 부름이 실제와 정합하는가를 묻는 문제이다. 식품 표시의 비유가 이 점을 잘 드러낸다. 딸기맛 제품을 만들지 말라는 이야기가 아니라, 실제 원재료·함량·향료 사용과 맞지 않게 소비자가 딸기 성분에 관한 기대를 갖게 만드는 표시가 문제라는 이야기다. 마찬가지로 정보정리·검색·기록·질문정리·참고자료 제공에 그치는 서비스가 인간 전문가와 같은 판단을 수행하는 듯한 표지를 사용해서는 안 된다.

이런 관점에서 본고는 'AX 시대의 표지신의칙'을 제안한다. 본고가 말하는 표지신의칙은 독립된 위법유형이나 새로운 책임근거를 창설하는 원리가 아니다. 계약체결을 위한 접촉 또는 계속적 이용관계와 같은 구체적 법률관계에서, 적용 실정법과 판례가 허용하는 범위 안에서 AI 또는 AI 유사 표지

---

4) 그린워싱 규제에 관한 비교 연구로는 최유경·김혜리, 「E.S.G. 제도 구축의 관점에서 본 그린워싱(Greenwashing) 현황과 법제개선 방안」, 『환경법연구』 제45권 제1호, 한국환경법학회, 2023, 109-111면; 신의수·한재경, 「금융상품의 그린워싱 규제에 관한 연구」, 『법학논총』 제55집, 숭실대학교 법학연구소, 2023, 207-213면; 조재영, 「ESG 시대의 광고 규제 연구: 지속 가능한 녹색 소비를 위한 환경 관련 표시·광고를 중심으로」, 『차세대융합기술학회논문지』 제7권 제2호, 국제차세대융합기술학회, 2023, 311-312면의 Table 1 참조.

가 형성한 판단능력·전문가 관여·책임구조의 외관을 실제 기능·범위·한계·책임구조에 맞게 해석·조정하기 위한 민법 제2조상 신의칙의 보충적 평가원리이다. 표시광고법 등 공법적 규율에서는 민법 제2조가 직접 책임근거가 되는 것이 아니라, 결합표지의 전체적 외관과 실질을 포착하여 오인성·실증 등 해당 법률의 요건을 구조화하는 분석틀로만 기능한다. 따라서 표시광고법·계약법·약관법·전문직역법 등 개별 규율의 요건과 효과를 대신하지 않는다.

특히 전문자격표지와 결합할 때 이 원칙의 의미는 한결 분명해진다. "변호사"·"의사"·"약사"·"세무사"는 단순한 직업명이 아니라 자격취득·교육·윤리·징계·배상책임·직역질서가 오랜 시간 쌓아 올린 제도적 신뢰의 응축어이다. 인간 전문가는 이 표지를 쓰기 위해 적지 않은 자격취득 비용과 책임부담을 감수한다. 그런데 AI 서비스가 "AI 변호사"·"AI 의사"와 같은 결합표지로 그 제도적 신뢰를 손쉽게 끌어다 쓴다면, 표지와 실질의 균형은 무너진다.[5)]

3. 정당한 신뢰의 문제

AI 표지가 일정한 신뢰를 환기할 수 있다고 하여 그 신뢰가 언제나 법적으로 보호되어야 하는 것은 아니다. AI-Washing의 법적 평가는 이용자가 AI를 믿었는지 또는 그 신뢰가 얼마나 강했는지를 묻는 데 그치지 않고, 표지가 형성한 기대가 실제 서비스의 기능·범위·한계 및 책임구조에 비추어 객관적으로 정당화될 수 있는지를 묻는다. 실제 기능과 한계, 인간 전문가의 관여 및 책임주체가 적절히 제시되어 이용자가 그에 맞는 기대를 형성하였다면 이는 정당한 AI 신뢰에 가깝지만, 명칭·광고·인터페이스가 실제보다 높은 판단능력이나 전문성을 암시하였다면 그 신뢰는 왜곡될 수 있다. 이하에서는 이러한 신뢰가 형성되는 구조를 살핀 뒤, 제Ⅳ장에서 그 외관과 실질의 정합성을 법적 평가의 관점에서 검토한다.

---

5) 전문자격명칭의 식별·신뢰 보호 기능에 관하여는 후술할 각주 14 참조.

4. 연구의 목적과 범위

본고의 목적은 AI-Washing을 판단외관과 표지신의칙의 관점에서 다시 짜보는 데 있다. 이때 AI의 실제 사용 여부를 출발점으로 삼되, 법률상 AI에 해당한다는 사실만으로 표지와 실질의 정합성이 확보된다고 보지 않고, 실제 기능·적용범위·성능 및 인간의 관여와 책임구조까지 함께 살핀다. 그 흐름 안에서 "AI 변호사"와 같은 결합표지가 전문신뢰를 빌려 쓰는 방식을 들여다보고, AI-Washing을 정당한 AI 신뢰와 왜곡된 AI 신뢰의 구별 문제로 다룬다. 끝으로 AI-Washing이 기존 외관신뢰법리와 구조적으로 맞물린다는 점을 보이되, 표현대리·명의대여·표시광고법·전문직역법의 직접 적용을 주장하지는 않는다. 이들 법리가 공통적으로 전제하는 외관·정당한 신뢰·귀속 가능성의 구조를 AI 판단외관 문제에 비추어 다시 읽는 정도로 그친다.

본고는 AI 서비스의 구체적 손해배상책임과 입증책임의 배분, 일반적인 성능검증의무나 신뢰성 인증제도의 설계, AI 운영주체의 조직법적 요건 및 고위험 판단지원 AI의 허용구조까지 포괄하지 않는다. 다만 AI-Washing의 판단을 위해 필요한 범위에서는 AI의 실제 사용 여부와 기능·적용범위·성능, 검증수준, 인간 전문가의 관여와 책임구조를 표지가 형성한 외관과 비교한다. 특히 일정한 성능이나 전문적 판단능력이 표시된 경우에는 그 표시가 실제 제공된 서비스의 조건에서 객관적으로 뒷받침되는지를 표지-실질 정합성 판단의 요소로 다룬다.

Ⅱ. 혁신표지의 계보와 판단외관의 형성

1. 현행법상 AI 개념과 실질 판단의 전제

현행 「인공지능 발전과 신뢰 기반 조성 등에 관한 기본법」은 '인공지능'을 학습·추론·지각·판단·언어의 이해 등 인간의 지적 능력을 전자적 방법으로

구현한 것으로 정의하고, ‘인공지능시스템’을 다양한 수준의 자율성과 적응성을 가지고 주어진 목표를 위하여 실제 및 가상환경에 영향을 미치는 예측·추천·결정 등의 결과물을 추론하는 인공지능 기반 시스템으로 구분한다. 이러한 포괄적 정의는 해당 기술이나 서비스가 법률상 인공지능에 해당하는지를 확인하는 출발점이지만, 개별 서비스의 과업수행능력·자료접근성·적용범위·검증수준·인간 관여 및 책임구조까지 확정하지는 않는다. 따라서 AI-Washing의 평가는 법적 해당성을 확인한 다음, 실제 제공서비스의 실질을 구체적으로 특정하여 표지가 형성한 외관과 비교하는 단계로 나아가야 한다.[6)]

2. 혁신표지의 계보와 AI의 특수성

AI-Washing을 이해하려면 “AI”라는 말이 상품과 서비스에 들러붙는 현상을 고립적으로 보아서는 안 된다. 새로운 기술이나 시대정신을 담은 단어가 상호·상품명·광고 문구·서비스 설명에 붙어 첨단성과 신뢰를 빚어내는 흐름은 반복되어 왔고, 이 글은 그러한 표지를 ‘혁신표지’라 부른다. 혁신표지는 멋스러운 수식어가 아니라 한 시대가 기술에 걸어 둔 기대를 상품과 서비스로 옮겨 놓는 장치다. 유인 우주선과 달 탐사가 화두였던 시절의 “우주”는 미래성과 문명 진보의 이미지를 끌어모았고, 컴퓨터 보급기의 “컴퓨터”는 그 단어 자체가 자동화이자 정확성이자 기계적 합리성을 호명하는 표지가 되었으며, 그 뒤로 “나노”와 “바이오”가 과학성과 정밀성을, 다시 “클라우드”와 “스마트”가 연결성과 미래 인프라의 이미지를 차례로 빌려 입었다.

이러한 흐름은 기업·조직의 정당성 확보 전략으로도 풀린다. 제도화 조직론은 기업이 사회적으로 정당화된 기술표지를 수용하여 정당성이나 자원을 확보하려는 유인을 설명한다. 본고는 이 논의를 AI 표지가 채택되는 사회적 배경을 설명하는 데 한정하여 원용한다.[7)]

---

6) 「인공지능 발전과 신뢰 기반 조성 등에 관한 기본법」 제2조제1호·제2호(법률 제21311호, 2026. 1. 20. 일부개정, 2026. 7. 21. 시행).

7) 조직이 제도화된 환경 속에서 합리화된 신화와 형식의 채택을 통하여 정당성·자원·안정성을 확보한다는 분석은 제도적 조직론의 고전적 통찰이다. Meyer, J. W., & Rowan, B. (1977).

그러나 AI 표지의 특수성은 바로 그 반복을 깨뜨리는 지점에 있다. 기존 혁신표지가 상품과 서비스에 부여한 기대는 대체로 '기능 향상'이었다. "우주"는 미래성과 첨단성을, "컴퓨터"는 자동성과 정확성을, "나노"·"바이오"는 과학성과 정밀성을 암시했다. "AI"는 그 단순한 기능 향상의 기대를 넘어선다. AI 표지는 해당 시스템이 자료를 이해하고 맥락을 파악하며 선택지를 비교한 뒤 결론을 제시할 수 있다는 기대, 곧 판단능력에 관한 기대를 함께 호출한다. 자동화된 세탁기는 세탁을 더 편리하게 해 주리라는 기대를 만들지만, "AI 법률상담"은 이용자의 법률문제를 분석해 방향을 제시해 주리라는 기대를, "AI 의료상담"은 건강정보 검색을 넘어 증상과 위험을 분류해 주리라는 기대를, "AI 세무상담"은 세법 조문 검색이 아니라 개별 사안에 적용 가능한지에 관한 판단을 호출한다. AI는 자동성·과학성 표지의 연장이 아니라 인간 전문가의 판단기능에 닿는 신뢰표지가 된다.

바로 그 때문에 AI-Washing은 기존의 과장광고나 혁신표지 오용보다 한결 복합적이다. 실제로 AI를 쓰더라도 그 AI가 수행하는 일이 검색·정리·분류에 머무는데 이용자에게 전문적 판단을 제공하는 것처럼 표시된다면, AI-Washing은 그대로 성립한다. 다만 AI가 인간 전문가의 지식을 학습했다고 해서 그 제도적 신뢰까지 자동으로 물려받는 것은 아니다. 법률문서와 판례를 학습한다고 변호사가 되지 않고, 의학자료를 학습한다고 의사가 되지 않는다. 전문직의 신뢰는 지식량이 아니라 자격취득·윤리·징계·배상·제도적 통제에서 나온다. 그러므로 AI의 특수성은 "AI는 위험하다"는 명제가 아니라, AI 표지가 인간 전문가의 제도적 신뢰를 부분적으로 빌릴 수 있다는 사실에서 찾아야 한다.

<표 2> AI 서비스의 실질을 특정하는 다섯 좌표

실질요소	확인할 내용
산출주체·관여구조	결과 생성·선택·수정에 인간과 자동화 시스템이 어떻게 관여했는가

Institutionalized organizations: Formal structure as myth and ceremony. American Journal of Sociology, 83(2), pp. 344–345, https://doi.org/10.1086/226550 참조.

모델·배포구성	표시된 기능·성능과 관련하여 실제 어떤 시스템 구성과 도구가 사용되었는가
기능·적용범위	실제 수행하는 과업과 제외되는 영역은 무엇인가
성능·과업적합성·검증	표시된 성능이나 전문성이 실제 과업·제공조건에서 뒷받침되는가
감독·책임구조	인간 또는 전문가의 검토·통제 범위와 오류 대응·책임 귀속은 어떠한가

특정 모델의 일반적 성능이 높더라도 최신 자료 접근이나 필요한 도구가 결여되면 특정 과업에는 적합하지 않을 수 있고, 상대적으로 제한된 시스템이라도 범위가 좁고 적절히 검증된 과업에서는 충분히 기능할 수 있다. 따라서 평가의 초점은 모델의 명성이나 규모 자체가 아니라 표지가 제시한 기능·성능과 실제 서비스 구성의 정합성에 있다.

3. AIoid: 인간·서비스·조직이 AI를 닮는 표상 구조

AI의 특수성은 AI가 인간을 닮는 데서만 드러나지 않는다. 인간·서비스·조직·문서가 오히려 AI의 형식을 닮아 자율적이고 객관적이며 고도의 분석 능력을 갖춘 것처럼 제시되는 경우도 있다. 본고는 이러한 표상구조를 ‘AIoid’라 부른다. AIoid는 실제 AI 사용 여부와 반드시 일치하지 않으며, 대화형 인터페이스, ‘분석 중입니다’와 같은 표현, 단계적 분석형식이나 확률·점수·전문자료의 인용 등이 결합하여 보다 고도화된 판단이 이루어지는 듯한 외관을 형성하는 경우를 포함한다.

다만 AIoid 자체가 곧 AI-Washing을 의미하는 것은 아니다. AIoid는 판단 외관이 형성되는 표상 경로이고, AI-Washing은 그러한 외관이 실제 서비스와 중대하게 어긋나는 경우에 문제된다. 최근 논의된 ‘인공지능의 권위 외관’이 플랫폼 운영자의 지배적 거래관여를 객관적·중립적 알고리즘의 결과처럼 포장하는 위장 구조와 그 책임귀속에 초점을 둔다면, AIoid는 보다 넓게 인간·서비스·조직·문서가 AI의 형식을 모사하는 표상구조를 가리킨다. 따라서 AIoid는 대체개념이나 독립된 위법유형이 아니라 판단외관의 형성경로를 설명하기 위한 개념이다.[8)]

4. AI가 신뢰표지가 되는 구조

어떤 표지가 신뢰표지로 기능한다는 것은 그 표지가 대상을 지칭하는 데 그치지 않고 그 대상의 능력·품질·책임 또는 권위에 관한 기대를 함께 형성한다는 뜻이다. 오늘날 'AI'라는 표지 역시 단순히 특정한 기술수단이 사용되었다는 사실만을 나타내지 않고, 일정한 자료처리와 분석을 거쳐 판단이 이루어지고 있다는 외관을 형성할 수 있다. 본고가 특히 주목하는 것은 이러한 판단능력에 관한 외관이다. AI 표지가 그러한 외관을 형성하는 배경은 크게 데이터 기반성, 객관성, 자율성, 전문성, 속도와 규모의 다섯 측면에서 설명할 수 있다. 이용자는 AI가 많은 자료를 처리하여 계산적 근거에 따라 결과를 도출하고, 인간의 피로와 실수로부터 상대적으로 자유로운 일관된 처리를 하며, 입력된 정보를 스스로 해석하여 답을 구성하고, 해당 분야의 전문자료를 활용하며, 인간보다 빠른 속도로 대규모 정보를 검토할 수 있다고 기대할 수 있다. 이들 요소가 결합할수록 AI 표지는 단순한 기술표지를 넘어 일정한 판단능력을 암시하는 표지로 기능할 가능성이 커진다.

다만 여기서 AI 표지가 모든 이용자에게 또는 모든 의미에서 신뢰를 높인다는 뜻은 아니다. 신뢰는 하나의 단일한 심리상태로만 파악하기 어렵다. AI 사용 사실은 공감·친밀감·진정성과 같은 관계적 신뢰를 오히려 낮출 수도 있는 반면, 계산능력·자료처리능력·일관성·속도와 같은 능력에 관한 신뢰는 높일 수 있다. 또한 자격·윤리·감독·책임에 관한 제도적 신뢰는 AI라는 표지 자체에서 당연히 발생하는 것이 아니라, 'AI 변호사'나 'AI 의사'처럼 전문자격표지가 결합되는 경우 별도로 문제된다. 따라서 본고에서 AI가 '신뢰표지'라고 할 때 주된 의미는 AI라는 명칭과 표상이 이러한 모든 형태의 신뢰를 일률적으로 증가시킨다는 데 있지 않고, 특히 시스템의 판단능력과 전문성에 관한 일정한 기대 또는 외관을 형성할 수 있다는 데 있다.

---

8) 알고리즘 규율과 투명성에 관하여는 오정하·김일환, 「지능정보사회에서 알고리즘의 법·규제의 방향」, 『법과정책』 제27권 제3호, 2021, 132-134면; 인공지능의 '권위 외관'과 외관신뢰 구조에 관하여는 나태수, 「자동화된 지배적 거래관여와 인공지능의 권위 외관—신뢰책임론에 기초한 부진정연대채무 법리—」, 『소비자법연구』 제12권 제2호, 2026, 141면, 149-151면 참조. AIoid는 이러한 논의를 토대로 본고가 제안하는 설명개념이다.

그러므로 AI-Washing의 규범적 초점도 AI에 대한 신뢰가 존재하는가, 또는 그 신뢰가 강한가에 놓이지 않는다. 중요한 것은 AI 표지가 구체적으로 어떠한 능력·전문성·책임구조의 외관을 형성하였고, 그러한 외관이 실제 서비스의 기능·적용범위·성능·한계 및 감독·책임구조와 정합하는가이다. 자동화 신뢰 연구가 적정한 의존과 조정된 신뢰를 강조해 온 것처럼, 본고 역시 신뢰의 양 자체보다 표지가 형성한 기대가 실제 시스템의 능력에 맞게 조정되어 있는지를 문제 삼는다. 이러한 표지에 의해 형성되는 판단능력의 외관을 이하에서는 '판단외관'의 관점에서 구체적으로 살펴본다.[9)]

5. 판단외관의 네 층위

판단외관은 하나의 인상으로만 형성되지 않는다. AI 또는 AI 유사 표지는 명칭·광고문구·전문자격표지·대화형 인터페이스·결과의 제시방식과 한계 고지가 결합되는 과정에서, 이용자에게 누가 판단하는지, 어떠한 과정을 거치는지, 무엇을 근거로 하는지, 그리고 그 판단이 어떠한 감독과 책임구조 아래 놓여 있는지에 관한 외관을 형성할 수 있다. 본고는 이를 판단 주체의 외관, 판단 과정의 외관, 판단 근거의 외관, 감독·책임구조의 외관이라는 네 층위로 나누어 살펴본다. 여기서 판단외관은 이용자가 실제로 AI를 인간이나 법적 주체라고 믿었다는 주관적 상태를 뜻하지 않는다. 명칭·표현·인터페이스 등 서비스가 제시한 표지를 전체적으로 볼 때 일정한 판단능력과 전문성의 존재를 기대하게 할 수 있는 객관적 외관을 가리키며, 개별 이용자가 그러한 외관을 실제로 신뢰하였는지와 그 신뢰가 정당한지는 이후의 평가단계에서 별도로 살펴야 한다.[10)]

첫째는 판단 주체의 외관이다. 이는 이용자가 AI 또는 AIoid 서비스를 단

9) 자동화 신뢰에서 적정한 의존(appropriate reliance)과 신뢰의 조정(calibration)을 강조하는 연구로 Lee, J. D., & See, K. A. (2004). Trust in automation: Designing for appropriate reliance. Human Factors, 46(1), pp. 50–53, https://doi.org/10.1518/hfes.46.1.50_30392 참조.

10) Nass, C., Steuer, J., & Tauber, E. R. (1994). Computers Are Social Actors. In Proceedings of the SIGCHI Conference on Human Factors in Computing Systems (pp. 72–78). ACM, p. 77, https://doi.org/10.1145/259963.260288.

순한 정보저장소나 도구가 아니라, 자신의 질문과 사안을 이해하고 일정한 판단을 수행하는 대상으로 마주하고 있다고 받아들이게 되는 외관을 말한다. 자연어 대화, 문맥을 이어가는 응답, 이용자의 상황에 맞춘 듯한 표현은 이러한 외관을 강화하고, 'AI 상담사', 'AI 변호사', 'AI 의사'와 같은 명칭은 여기에 전문적 판단주체의 인상까지 덧붙일 수 있다. 여기서 말하는 '판단 주체'는 AI에 권리능력이나 행위능력이 있다는 의미가 아니다. 중요한 것은 실제 결과의 산출주체와 관여구조가 무엇인가와 별개로, 서비스의 표면에서 누가 판단을 수행하는 것처럼 제시되는가이다. 따라서 판단 주체의 외관은 앞서 살핀 실제 산출주체·관여구조와 대조되어야 한다.

둘째는 판단 과정의 외관이다. AI 서비스는 결론만 제시하는 것이 아니라 그 결론이 검색·분석·비교·추론·위험분류 또는 검증과 같은 절차를 거쳐 도출된 것이라는 인상을 함께 형성할 수 있다. '분석 중입니다', '관련 판례를 검토하고 있습니다', '최적의 답변을 생성하고 있습니다'와 같은 문구뿐 아니라 응답지연, 단계별 분석 화면, 항목별 비교표, 확률이나 점수의 제시도 그러한 외관을 강화한다. 그러나 실제 처리과정이 단순한 검색·규칙분기 또는 일반적인 생성형 AI 응답에 머물면서도 복수의 자료와 대안을 전문적으로 비교·검증한 것처럼 표시될 수 있다. 따라서 판단 과정의 외관은 실제 서비스가 수행한 처리절차와 비교되어야 한다.

셋째는 판단 근거의 외관이다. AI라는 표지는 그 자체로 데이터와 계산에 근거한 결과라는 인상을 형성할 수 있고, 법령·판례번호·논문명·통계수치·위험등급·확률과 같은 형식이 더해지면 그 판단이 객관적이고 검증 가능한 자료에 기초하였다는 기대가 강화된다. 특히 법률·의료·금융·세무처럼 이용자가 근거의 정확성과 최신성을 즉시 확인하기 어려운 영역에서는 이러한 형식적 근거의 제시가 강한 판단외관을 만들 수 있다. 그러나 제시된 자료가 실제로 존재하는지, 최신 자료인지, 해당 사안과 관련되는지, 필요한 반대자료까지 검토되었는지는 별개의 문제이다. 따라서 판단 근거의 외관은 실제 자료접근성·최신성·검증수준 및 과업적합성과 대조하여 살펴야 한다.

넷째는 감독·책임구조의 외관이다. 이용자는 AI 서비스의 결과만을 접하지만, 전문적 판단에 대한 신뢰에는 누가 그 결과를 감독하고 오류가 발생했

을 때 누가 이를 검토·수정하며 책임을 부담하는가에 관한 기대도 포함될 수 있다. 특히 ‘AI 변호사’, ‘AI 의사’와 같이 전문자격표지가 결합되면 그 명칭은 단순한 지식이나 판단능력뿐 아니라 인간 전문가의 검수, 윤리규범, 비밀유지, 품질관리, 이의제기와 책임부담과 같은 제도적 구조까지 연상시킬 수 있다. 그러나 AI 자체는 그러한 자격·징계·책임의 주체가 아니며, 실제 감독과 책임은 서비스 운영자·전문가·개발자 또는 플랫폼 등 다른 주체에게 귀속될 수 있다. 따라서 누가 결과를 검토하는지, 인간 전문가의 관여가 실제로 존재하는지, 오류나 분쟁이 발생한 경우 책임과 재검토가 어디로 이어지는지는 판단외관과 실제 서비스의 실질을 비교하는 중요한 요소가 된다.

Ⅲ. AI+전문자격표지와 전문신뢰의 차용

1. 전문자격표지의 제도적 신뢰

AI-Washing의 위험은 AI 표지가 단독으로 쓰일 때보다 전문자격표지와 결합할 때 한층 커진다. “AI 변호사”·“AI 의사”·“AI 세무사”·“AI 약사”라는 표현은 AI 기술을 쓴다는 의미에 머무르지 않는다. AI의 자율성·지성·객관성에 관한 기대와, 인간 전문가 제도가 오랜 시간 쌓아 온 자격·책임·윤리의 신뢰가 하나의 표지로 묶인다. 전문자격표지는 단순한 직업명칭이 아니다. “변호사”·“의사”·“세무사”는 시험·교육·자격취득·등록·윤리규범·징계·책임구조를 통과한 자에게 부여되는 제도적 신뢰의 응축어이다. 이용자는 “변호사”라는 말을 접할 때 법률지식을 가진 사람만 떠올리지 않고, 법률문제를 처리할 자격과 책임을 함께 가진 전문가를 떠올린다.

이러한 전문서비스는 경제학에서 말하는 신뢰재(credence good)에 해당한다. 신뢰재 시장에서 소비자는 서비스를 받기 전뿐 아니라 받은 뒤에도 그 서비스가 정말 필요했는지, 제공된 품질이 적절했는지, 전문가의 판단이 타당했는지를 완전히 평가하기 어렵다.[11] 출처신뢰성 연구도 메시지의 설득 효

과가 내용뿐 아니라 출처의 전문성과 신뢰가능성에 좌우된다는 점을 거듭 확인해 왔다.[12] "변호사"·"의사"·"세무사"라는 표지는 정보의 내용 이전에 정보가 어떤 출처에서 나온 것인지에 관한 신뢰를 구성한다.

우리 법체계도 전문자격명칭을 단순한 직업의 설명에 맡겨 두지 않고 자격·면허제도와 결부하여 규율한다.[13] 변호사법 제112조 제3호는 변호사가 아니면서 '변호사'나 '법률사무소'를 표시·기재하거나, 이익을 얻을 목적으로 법률상담이나 그 밖의 법률사무를 취급한다는 뜻을 표시·기재하는 행위를 처벌한다. 의료법 제27조 제1항은 의료인이 아닌 자의 의료행위와 의료인의 면허범위를 벗어난 의료행위를 금지하고, 같은 조 제2항은 의료인이 아닌 자가 의사·치과의사·한의사·조산사 또는 간호사 명칭이나 이와 비슷한 명칭을 사용하는 것을 금지한다. 이러한 규율은 적어도 '변호사'나 '의사'와 같은 전문자격명칭의 사용이 그 명칭에 대응하는 자격·면허와 분리될 수 없는 법적 의미를 가진다는 점을 보여 준다. 이용자에게 전문서비스 제공자의 자격과 전문성을 식별하게 하는 명칭의 기능은 세무사 명칭 사용 제한에 관한 헌법재판소의 판단에서도 확인된다. 따라서 전문자격표지는 단순한 직업명이 아니라 이용자가 서비스 제공자의 전문적 지위와 업무능력을 식별하는 중요한 표지로 기능한다.[14]

---

11) 법률·의료·세무 서비스의 신뢰재(credence good) 성격에 관하여는 Emons, W. (1997). Credence Goods and Fraudulent Experts. RAND Journal of Economics, 28(1), pp. 107-108, https://doi.org/10.2307/2555942 참조.

12) 메시지의 설득 효과가 메시지 내용뿐 아니라 출처의 신뢰성과 전문성에 의해 좌우된다는 점은 출처 신뢰성(source credibility) 연구가 일관되게 지적해 온 바이다. Hovland, C. I., & Weiss, W. (1951). The influence of source credibility on communication effectiveness. Public Opinion Quarterly, 15(4), pp. 640, 645 (Figure 1 및 Table 7), https://doi.org/10.1086/266350 참조.

13) 변호사법 제112조제3호; 의료법 제27조제1항·제2항. 대법원 2022. 7. 28. 선고 2019도7563 판결은 변호사법 제112조제3호의 '변호사를 표시 또는 기재'한 행위인지 여부를 명칭 사용의 경위와 방법, 표시 내용의 전체적 맥락 및 변호사 자격에 관한 오인 가능성 등을 종합하여 판단하여야 한다고 보았다.

14) 헌법재판소 2008. 5. 29. 선고 2007헌마248 결정(세무사법 제20조 제2항 위헌확인)은, 세무사 자격명칭 사용 제한의 입법목적이 자격명칭의 공신력을 제고하고 소비자가 세무사자격시험 합격자와 그 외의 세무사 자격소지자를 구분하여 합리적으로 세무서비스를 선택할 기회를 보장하는 데 있다고 보아 합헌으로 판단하였다. 한편 헌법재판소 2018. 4. 26. 선고 2015헌가19 결정(세무사법 제6조 등 위헌제청)은 세무사 자격을 가진 변호사에게 세무대리를 전면 금지한 부분에 대하여 직업선택의 자유를 침해한다는 이유로 헌법불합치 결정을 하고 2019. 12. 31.까지 잠정 적용을 명하였다. 두 결정은 전문자격명칭 규제가 '명칭에 의한 식별 보호'와 '업무 영역 보호'의 두 층위에서 작동함을 보여 준다.

다만 이러한 규정이 존재한다는 사실만으로 ‘AI 변호사’나 ‘AI 의사’라는 결합표지가 곧바로 각 형벌규정의 구성요건에 해당한다고 단정할 수는 없다. 특히 변호사법 제112조 제3호와 같은 형벌규정의 적용은 사용된 명칭의 문언과 표시방법, 전체적인 맥락 및 자격에 관한 오인 가능성 등을 개별적으로 살펴 엄격하게 판단하여야 한다. 본고가 제안하는 표지신의칙 역시 전문직역법의 처벌범위를 확장하기 위한 근거가 아니라, 이러한 결합표지가 이용자에게 어떠한 전문성·판단능력·책임구조의 외관을 형성하는지를 민사·행정적 평가에서 함께 고려하기 위한 보충적 평가원리로 이해되어야 한다.

2. AI+전문자격 결합표지의 이중구조

“AI 변호사”라는 표현은 일반적인 자격사칭과 다르게 작동한다. 무자격자인 자연인이 자기 이름 앞에 “변호사”를 붙이면 그 표현은 곧바로 자격의 외관을 만든다. 반면 “AI 변호사”는 겉으로 다른 구조를 띤다. 이용자는 대체로 AI가 인간 변호사가 아님을 알고, “AI”라는 수식어는 자연인 변호사가 아니라는 점을 드러내 자격사칭의 위화감을 줄이는 완충표지로 작동한다. 그러나 문제가 사라지지는 않는다. “AI”라는 수식어가 자격사칭의 위험을 누그러뜨리는 듯 보여도, 뒤에 붙은 “변호사”는 여전히 법률전문가적 판단에 관한 기대를 호출한다. 이용자는 그것이 인간 변호사가 아님을 알면서도 그 서비스가 법률문제를 이해하고 사안을 분석하며 해결 방향을 제시할 수 있다고 기대한다.

이러한 AI+전문자격 결합표지의 위험은 미국 FTC의 DoNotPay 사건에서 구체적으로 드러난다. DoNotPay는 서비스를 ‘AI lawyer’, ‘world’s first robot lawyer’ 등으로 홍보하면서 법률문서 작성과 개별 법률문제에 관한 조언에서 인간 변호사와 유사한 기능을 수행한다는 외관을 형성하였다. FTC의 complaint는 서비스가 이용자에게서 소수의 사실만 입력받았고, 포괄적·최신의 법령·판례 자료를 바탕으로 설계되지 않았으며, 대부분의 법률기능에 대하여 품질·정확성 시험이나 변호사 검수를 거치지 않았다고 주장하였다. 다만 이는 동의명령으로 종결된 절차에서 제기된 FTC의 주장이고, DoNotPay

가 그 사실을 인정한 것은 아니다. 최종명령은 인간 변호사처럼 작동한다거나 전문서비스를 해당 분야의 전문가처럼 수행한다는 표시를 하려면, 표시 당시 관련 분야에서 일반적으로 받아들여지는 기준에 비추어 충분한 질과 양의 신뢰할 수 있는 근거를 보유하고 이에 의존하도록 하였다.[15]

이 사례는 'AI lawyer'라는 명칭 자체의 일반적 금지보다, 전문자격표지가 형성한 외관의 강도에 상응하는 기능·검증·전문가 관여의 근거가 요구된다는 점을 보여 준다. 제Ⅳ.4에서는 이 공개기록을 본고의 다섯 단계에 대입한다.

그러므로 문제는 AI를 활용한 법률서비스 자체를 금지하는 데 있지 않다. AI가 법률정보의 검색·정리·요약이나 문서작성 지원과 같은 기능을 수행한다면 그 실제 기능과 한계를 그에 맞게 표시하면 된다. 반면 서비스가 개별 사안을 분석하여 인간 변호사에 준하는 전문적 판단을 제공하는 것처럼 표시한다면, 그러한 외관이 실제 기능·적용범위·검증수준 및 전문가의 감독·책임구조에 의해 뒷받침되는지를 별도로 살펴야 한다. 이 구별은 전문자격표지의 사용 자체를 일률적으로 금지하기 위한 것이 아니라, 결합표지가 끌어오는 전문신뢰와 실제 서비스의 실질 사이의 정합성을 묻기 위한 것이다.[16][17]

3. 의료·약사·세무 영역으로의 확장

AI와 전문자격표지가 결합하는 문제는 법률서비스에 한정되지 않는다. 'AI

---

15) Federal Trade Commission, In the Matter of DoNotPay, Inc., Matter No. 232-3042, Docket No. C-4812, Complaint ¶¶ 4, 19-21, 28-31 (issued Jan. 14, 2025); Decision and Order, Decision at 1 & Order, Provision I (issued Jan. 14, 2025). 전자는 FTC의 사실주장이고, DoNotPay는 관할 성립에 필요한 사실 외에는 그 주장을 인정하지 않았다. 최종 동의명령은 전문서비스 성능표시에 관련 분야의 기준상 충분한 질과 양의 'competent and reliable evidence'를 요구한다. Federal Trade Commission, 'FTC Finalizes Order with DoNotPay That Prohibits Deceptive "AI Lawyer" Claims,' Feb. 11, 2025, https://www.ftc.gov/news-events/news/press-releases/2025/02/ftc-finalizes-order-donotpay-prohibits-deceptive-ai-lawyer-claims-imposes-monetary-relief-requires (최종접속일: 2026. 8. 8.).

16) 변호사의 AI 사용에 따른 적격성의무·설명의무·비밀유지의무에 관하여는 강윤희, 「변호사의 인공지능 사용과 관련한 윤리규범—인공지능이 변호사를 대체할 수 있을까의 관점에서」, 『경영법률』 제33권 제4호, 2023, 61-64면 참조.

17) AI 에이전트가 사용자를 대신하여 법률행위를 수행할 때의 효력귀속과 책임구조에 관하여는 오병철, 「AI 에이전트에 의한 의사표시의 효력 근거」, 『연세법학』 제50호, 2026, 305-343면, 특히 319면 참조.

의사', 'AI 약사', 'AI 세무사'와 같은 표현에서도 AI 표지가 형성하는 판단 능력의 외관과 각 전문직역이 축적해 온 자격·전문성·책임에 관한 제도적 신뢰가 결합할 수 있다. 다만 각 직역이 수행하는 업무와 이를 규율하는 법률의 구성요건은 서로 다르므로, 결합표지의 법적 평가는 각 법률에 따라 구체적으로 이루어져야 한다. 본고가 주목하는 공통점은 전문자격명칭이 단순한 직업표시를 넘어 일정한 전문적 판단과 제도적 통제가 존재한다는 기대를 형성할 수 있다는 데 있다.

"AI 의사"는 의료인 신뢰를 AI 표지와 묶는다. 이용자는 그것이 인간 의사가 아님을 알면서도 "의사"라는 단어에서 증상 이해, 질병 가능성 평가, 위험도 분류, 치료 방향 제시, 병원 방문 필요성 판단을 기대한다. 의료법이 의료인이 아닌 자의 의료행위와 의사·치과의사·한의사·조산사·간호사 명칭 사용을 모두 막고 있다는 점은[18] 이 영역의 명칭 외관 보호 강도를 그대로 보여 준다. 약사·복약상담 영역도 다르지 않다. 약사법은 약사 또는 한약사가 아니면 약국을 개설할 수 없도록 하고, 등록된 약국이 아니면 약국의 명칭이나 이와 비슷한 명칭을 사용하지 못하도록 하며, 약사 및 한약사가 아니면 의약품을 조제할 수 없도록 정한다.[19]

세무 영역에서도 세무사는 세법을 아는 사람이 아니라 세무대리·신고·조정·불복 등 특정 세무서비스를 제공하는 자격체계 안에 자리하며[20], "AI 세무사"라는 표현은 그 세무사 표지의 신뢰를 AI의 기술 신뢰와 결합한다. 결합구조는 법률·의료·약사·세무 영역에서 공통적으로 나타나며, 두 외관이 겹치는 순간 이용자의 신뢰는 단단해진다.

---

18) 「의료법」 제27조 제1항·제2항. 제1항은 원칙적으로 비의료인의 의료행위 및 의료인의 면허범위를 벗어난 의료행위를 금지하고, 제2항은 의료인이 아닌 자의 의사·치과의사·한의사·조산사·간호사 명칭 또는 이와 비슷한 명칭의 사용을 금지한다.

19) 「약사법」 제3조 제3항, 제20조 제1항·제6항, 제23조 제1항. 제3조 제3항은 약사면허를 받지 않은 자의 '약사' 명칭 사용을 제한하고, 제20조 제1항·제6항은 약사 또는 한약사 이외의 자의 약국 개설과 등록된 약국이 아닌 자의 약국 또는 유사명칭 사용을 제한하며, 제23조 제1항은 원칙적으로 약사 및 한약사가 아닌 자의 의약품 조제를 금지한다.

20) 「세무사법」 제20조 제2항·제3항. 제2항은 등록한 자 외의 세무사 또는 유사명칭 사용을 제한하고, 제3항은 세무대리를 할 수 없는 자의 세무대리 취급 표시·광고 및 그와 같은 오인을 일으킬 우려가 있는 표시·광고를 제한한다.

4. ‘낮은 표지’의 의미

AI+전문자격 결합표지의 문제를 해결하는 방법은 강한 전문자격명칭을 보다 부드러운 표현으로 단순히 바꾸는 데 있지 않다. 예컨대 ‘AI 의사’라는 표현이 실제 서비스보다 강한 판단외관을 형성한다고 하여 이를 ‘AI 건강도우미’로 변경하는 것만으로 표지와 실질의 정합성이 확보되는 것은 아니다. ‘건강’, ‘도우미’, ‘상담’과 같은 표현 역시 사용맥락에 따라 일정한 효용·안전성·판단능력에 관한 기대를 형성할 수 있기 때문이다. 따라서 어느 명칭이 다른 명칭보다 추상적으로 강하거나 약한가만을 비교할 것이 아니라, 그 표지가 실제 서비스가 수행하는 과업의 내용과 수준에 부합하는지를 살펴야 한다.

이때 말하는 ‘표지를 낮춘다’는 것은 이러한 의미에서 명칭의 언어적 완화가 아니라 기능에 맞춘 표지의 구체화를 뜻한다. 실제 서비스가 이용자가 입력한 증상을 정리하거나 진료 전에 질문할 사항을 구조화하고 일반적인 의료정보를 검색하는 데 머문다면, 그 기능을 ‘증상기록’, ‘질문정리’, ‘의료정보탐색’과 같이 가능한 한 실제 과업에 가깝게 표시하는 것이 적절하다. 법률서비스에서도 판례·법령의 검색과 요약, 계약서의 문장정리, 사실관계의 구조화와 개별 사안에 대한 법률적 판단은 동일한 수준의 표지가 아니다. 세무·약사 영역에서도 자료정리나 일반정보 제공과 개별 사안에 대한 전문적 판단 또는 직역업무의 수행은 구별되어야 한다.

다만 표지의 적정성은 명칭 하나만을 떼어 판단해서는 안 된다. 동일한 ‘도우미’나 ‘정보서비스’라는 명칭을 사용하더라도 광고문구가 전문가 수준의 판단능력을 강조하거나, 대화형 인터페이스와 결과화면이 진단·상담·전문적 검토가 이루어진 것처럼 제시되거나, 전문가가 검수한 것처럼 표시된다면 전체적인 판단외관은 다시 강해질 수 있다. 반대로 서비스의 기능범위와 한계, 인간 전문가의 관여 여부 및 책임주체가 명확하게 제시되면 강한 외관이 일정 부분 교정될 수 있다. 따라서 ‘낮은 표지’는 특정 명칭을 사용하면 책임을 피할 수 있다는 면책표지가 아니라, 명칭·광고·인터페이스·결과형식·한계고지 및 전문가 관여 표시가 형성하는 전체적 외관을 실제 기능과 정

합시키는 문제로 이해해야 한다.

이러한 정합성 판단은 AI 또는 AI형 서비스 자체의 허용 여부를 결정하기 위한 기준이 아니다. 실제 기능이 정보검색·요약·분류 또는 판단지원에 머문다면 그 기능과 범위를 그에 맞게 표시하면 되고, 반대로 전문적 판단이나 진단·상담에 준하는 외관을 형성한다면 그에 상응하는 기능·검증수준·한계 고지와 감독·책임구조가 갖추어져 있는지를 살펴야 한다. 결국 평가의 초점은 명칭의 강약 자체가 아니라 표지가 형성한 전체적 외관과 실제 서비스의 실질 사이에 중대한 간극이 존재하는가에 있다.

Ⅳ. 표지-실질 정합성 판단과 외관신뢰법리의 접속

이 장은 명칭·광고·인터페이스·전문자격표지와 한계고지가 형성한 판단 외관을 실제 산출주체와 관여구조, 모델·배포구성, 기능·적용범위, 성능·검증수준 및 감독·책임구조와 비교하여 표지-실질 정합성을 검토한다.

제도화 조직론은 표지 채택의 유인을, 신호이론·신뢰재론은 정보비대칭 속 표지 의존을, 자동화 신뢰 연구는 기대를 실제 능력에 맞게 조정할 필요를 설명한다. 이는 판단외관과 검증가능성을 특정하는 사실적 자료일 뿐 법적 의무를 직접 도출하지 않으며, 구체적 평가는 표시광고법·인공지능기본법·계약법·약관법·전문직역법 등 적용 규범의 독자적 요건에 따른다.

1. 정당한 AI 신뢰와 왜곡된 AI 신뢰

AI-Washing 논의에서 먼저 피해야 할 오해는 AI 신뢰 그 자체를 부정적으로만 보는 시각이다. AI를 신뢰한다고 해서 그 신뢰가 늘 비합리적인 착각은 아니다. AI는 일정 영역에서 인간보다 빠르게 자료를 처리하고 반복 업무를 효율화하며 대량 정보를 구조화한다. 문제는 AI 또는 AIoid 표지가 실제 기능·범위·한계·책임구조보다 강한 판단능력과 전문성을 기대하게 만드는 경

우이다. 정당한 AI 신뢰는 이용자가 실제 기능·적용범위·한계·최신성·인간 전문가 관여 여부·책임구조에 관해 비교적 정확한 정보를 받고 그 정보를 바탕으로 적정한 기대를 형성하는 경우를 가리킨다.

왜곡된 AI 신뢰는 표지가 실제 기능보다 높은 판단능력·전문성·객관성·책임성을 암시하여 이용자에게 실제보다 강한 신뢰를 형성하게 하는 경우이다. 20대 소비자를 대상으로 한 국내 가전제품 실험에서도 AI-Washing 광고 노출 집단은 정직한 광고 집단보다 AI 기능과 제품 성능을 높게 평가하고 구매의도도 높았으며, 정보신뢰도는 두 집단 모두 높게 유지되었다. 이는 법이 물어야 할 것이 AI에 대한 호감 자체가 아니라 표지에 의해 형성된 능력·제도 신뢰가 실제 기능·한계·책임구조에 맞게 조정되었는가임을 뒷받침한다. 일부 연구에서 단순한 AI 사용 고지가 호감·신뢰를 낮춘다는 결과가 나타나더라도, 관계적 신뢰와 능력·제도 신뢰를 구별하면 양립할 수 있다.[21]

2. 표지의 강도와 정보비대칭

정당한 AI 신뢰와 왜곡된 AI 신뢰를 갈라 보려면 먼저 표지의 강도를 살펴야 한다. 표지는 같은 수준의 기대를 끌어오지 않는다. “AI 활용”과 “AI가 분석한 결과”는 다르고, “AI 법률정보 검색”과 “AI 변호사”는 다르며, “AI 건강정보 탐색”과 “AI 의사”는 다르다. 표지는 정보비대칭 상황에 들어가는 순간 그 무게가 달라진다. 이용자가 서비스의 내부 구조·데이터 품질·모델 성능·최신성·인간 전문가 관여 여부를 직접 확인하기는 사실상 어렵고, 그 자리에서 표지는 눈에 띄지 않는 품질이나 능력을 짐작하게 해 주는 '신호'로 일한다. 신호이론은 정보비대칭 상황에서 관찰 가능한 신호가 관찰 불가능한 능력이나 품질을 추정하게 만드는 기능을 일찍이 정리하였고,[22] 정보비대칭

---

21) 신지원·김은서·이인수·사지연, 앞의 논문, 62면, 66-67면; AI 사용 고지의 소비자 반응에 관하여는 김민정·이승민, 「AI 정보의 표시: AI기반 콘텐츠에 대한 소비자 반응」, 『비즈니스융복합연구』 제9권 제6호, 2024, 23-24면; 김민철, 「알고리즘 및 생성형 AI 고지의 양면적 효과에 관한 메타분석: 규제적 투명성과 설득 성과 사이의 맥락적 경계 조건을 중심으로」, 『콘텐츠와산업』 제8권 제1호, 2026, 320-321면 참조.

22) 정보비대칭 상황에서 관찰 가능한 신호가 관찰 불가능한 능력이나 품질을 추정하게 한다는 점은 신호이론의 고전적 분석이다. Spence, M. (1973). Job market signaling. The Quarterly Journal of

이 큰 시장에서는 품질 낮은 상품과 높은 상품이 구별되지 않아 시장 전체의 신뢰가 무너질 수 있다는 점도 같은 흐름에서 지적되어 왔다.[23]

법률·의료·세무 서비스는 신뢰재의 성격을 띠므로 이용자는 서비스를 이용한 뒤에도 그 판단이 정말 필요했고 적절했는지 완전히 평가하기 어렵다. 이런 시장에서는 전문자격표지와 AI 표지가 품질 검증을 갈음하는 역할을 떠맡기 때문에 표지와 실제 기능의 정합성이 더 큰 무게를 가진다. 표지가 강할수록, 전문영역일수록, 이용자의 검증 가능성이 낮을수록 표지-실질 정합성 요구는 한층 단단해진다.

생성형 AI 서비스의 실제 제공구성은 이용자에게 직접 드러나지 않는 경우가 많다. 동일한 명칭과 인터페이스를 사용하는 서비스라도 사용되는 모델, 외부자료 검색 여부, 결합도구 및 인간 전문가의 검토 등에 따라 구체적인 과업수행능력이 달라질 수 있으므로, ‘AI가 사용되었다’는 사실만으로 실제 제공된 기능·성능이 특정되는 것은 아니다. 다만 특정 모델의 규모·가격·명성 자체가 품질이나 위법성의 기준이 되는 것은 아니며, 중요한 것은 이용자에게 표시된 과업과 성능이 실제 제공조건에서 객관적으로 뒷받침되는가이다. 평가가 이루어진 조건과 실제 제공조건의 차이가 표시된 기능·성능과 실질적으로 관련되는 경우에는 그 차이를 표지-실질 정합성 판단에서 고려할 수 있다.

3. 기능적 구별 불가 환경과 검증 가능성

정당한 AI 신뢰 판단의 또 하나의 축은 이용자의 검증 가능성이다. 표지의 진위를 이용자가 쉽게 확인할 수 있었다면 그 신뢰의 보호가치는 떨어지고, 반대로 이용자가 표지와 실제 기능 사이의 어긋남을 스스로 가려내기 어려운 구조였다면 그 신뢰를 단순한 부주의로 치부하기는 어렵다. 생성형 AI가 일상으로 들어오면서 사람이 쓴 글과 AI가 만든 글 사이의 경계는 결과물만 들

Economics, 87(3), pp. 356–357, https://doi.org/10.2307/1882010.

23) 정보비대칭 시장에서 저품질 재화가 시장 전체의 신뢰를 훼손하는 역선택 문제에 관하여는 Akerlof, G. A. (1970). The Market for ‘Lemons’: Quality Uncertainty and the Market Mechanism. The Quarterly Journal of Economics, 84(3), 488–500, 특히 p. 495 참조.

여다봐서는 좀처럼 잡히지 않게 되었다. 글 한 편, 법률문서 초안, 보고서, 자기소개서, 계약서 요약, 판례 정리, 의료정보 설명, 세무 검토 메모 — 어디까지가 누구의 손에서 나왔는지를 결과만으로 추려내기란 사실상 어렵다. 본고는 이러한 상태를 '기능적 구별 불가 환경'이라 부른다. 생성형 AI 텍스트의 AI 작성률을 가늠해 준다고 내세우는 탐지 서비스의 등장 역시 그러한 환경이 이미 시장의 표면 위로 떠올라 있음을 보여 준다. 다만 이런 탐지 도구도 결국 확률적 판단의 영역에 머무르고, 한 실증연구는 그 안정성의 한계를 분명히 짚어두었다.[24)]

요컨대 기능적 구별 불가 환경은 AI-Washing 문제를 “AI가 실제로 있는지 없는지”에서 “무엇이 어떻게 표시되었는지”의 문제로 옮겨 놓는다. 이용자가 AI 여부를 스스로 가려내기 어렵다면, 표지는 단순한 광고문구가 아니라 신뢰의 구조적 기반이 된다.

4. 한계고지·출처·책임구조의 정합성

정당한 AI 신뢰의 판단은 표지의 강도와 정보비대칭만으로 끝나지 않는다. 이용자가 어떤 표지를 보았는지, 결과를 검증하기가 얼마나 어려웠는지에 더해, 서비스 제공자가 그 표지의 한계·근거·책임구조를 얼마나 드러냈는지까지 함께 살펴야 한다. 한계고지는 AI 또는 AIoid 표지가 만들어 낸 판단외관을 다시 조정하는 장치다. AI 서비스가 “분석·추천·진단·판단·상담” 같은 단어를 쓰는 순간 이용자는 일정한 판단능력을 기대하므로, 실제 기능이 정보검색·요약·문서정리·질문정리·단순 분류에 머문다면 그 한계는 표지의 표면 위로 분명히 떠올라야 한다.

한계고지와 외관교정의 문제는 현행 인공지능 규율의 투명성 의무와도 연결된다. 인공지능기본법 제31조는 일정한 인공지능 기반 제품·서비스의 AI 사용사실과 생성형 인공지능 결과물의 생성사실 등에 관한 고지·표시를 요

24) AI 생성 텍스트 탐지 도구들이 인간 작성물과 AI 생성물을 안정적으로 구별하지 못한다는 점은 실증적으로 보고된 바 있다. Weber-Wulff, D., et al. (2023). Testing of detection tools for AI-generated text. International Journal for Educational Integrity, 19, Article 26, PDF pp. 26–27, https://doi.org/10.1007/s40979-023-00146-z 참조.

구한다. 이러한 규율은 AI 또는 AI 생성물의 존재와 출처를 이용자가 인식하도록 한다는 점에서 중요하지만, 해당 서비스의 구체적인 기능·성능·적용범위나 인간 전문가의 관여·책임구조까지 보증하는 것은 아니다. 따라서 AI 사용사실의 투명성과 AI 표지가 형성한 판단능력의 외관과 실제 기능 사이의 정합성은 관련되어 있으나 서로 구별되는 문제이다.[25][26]

책임구조 역시 이러한 정합성 판단에서 독립적으로 살펴야 한다. 이용자가 직접 마주하는 것은 대화창·점수·추천 또는 분석결과이지만, 실제 서비스의 운영과 검토 및 오류대응은 AI 자체가 아니라 운영자·개발자·플랫폼 또는 인간 전문가 등의 관여구조를 통하여 이루어진다. 특히 전문자격표지가 결합된 서비스에서는 인간 전문가의 감독이나 검수가 실제로 존재하는지, 그 범위가 어디까지인지, 오류가 발생한 경우 재검토와 책임이 누구에게 이어지는지가 표지의 전체적 외관과 일치하는지를 살펴야 한다. 한계고지와 출처표시는 이와 같은 판단외관을 교정할 수 있지만, 주된 표지가 형성한 강한 전문성·판단능력의 외관을 실제로 수정할 정도로 구체적이고 현저하게 제시되었는지는 별도의 문제이다.

AI-Washing의 법적 평가는 표시광고법의 오인성 판단 및 실증제도와도 직접 연결된다. 표시·광고의 오인 가능성은 개별 단어의 진위만이 아니라 보통의 주의력을 가진 일반 소비자가 명칭·광고·인터페이스·수치·전문자격표지 및 한계고지의 결합에서 받는 전체적 인상을 기준으로 판단할 수 있다. 또한 사실에 관한 구체적인 기능·성능을 표시한 경우에는 표시광고법 제5조에 따라 그 내용을 객관적으로 뒷받침할 수 있는지가 문제되며, 평가조건과 실제 제공조건의 차이는 실증자료의 적합성 판단요소가 될 수 있다. 기준일 현재

---

25) 「인공지능 발전과 신뢰 기반 조성 등에 관한 기본법」 제31조(법률 제21311호, 2026. 1. 20. 일부개정, 2026. 7. 21. 시행); 같은 법 시행령 제23조(대통령령 제36506호, 2026. 7. 20. 일부개정, 2026. 7. 21. 시행). 투명성 의무의 해석과 고지의 현저성에 관하여는 노현숙, 「인공지능 투명성 의무의 해석과 입법적 재구성—「인공지능기본법」 제31조를 중심으로」, 『법제』, 2026. 6., 18-19면; 백수원, 「헌법상 투명성원칙에 기반한 인공지능 규제의 방향」, 『성균관법학』 제33권 제2호, 2021, 604-609면; 김정화·임동민·차호동, 「생성형 인공지능 기술의 규제 방향에 대한 입법론적 고찰」, 『형사법의 신동향』 통권 제80호, 2023, 255-262면 참조.

26) EU AI Act 제50조도 일정한 AI 상호작용과 인공 생성·조작 콘텐츠의 투명성 의무를 둔다. Regulation (EU) 2024/1689, art. 50, as amended by Regulation (EU) 2026/1744.

행정예고안인 공정위 공고 제2026-138호도 같은 방향이다.[27]

그러나 표시광고법과 본고의 표지-실질 정합성 판단은 동일하지 않다. 표시광고법이 구체적인 표시·광고의 오인성과 사실 관련 주장의 실증을 직접 규율한다면, 본고의 분석은 결합된 명칭·인터페이스·전문자격표지·한계·출처·책임표시가 어떠한 판단외관을 형성하고 그 외관이 실제 서비스와 정합하는지를 구조화하는 데 있다. 표시광고법이 적용되는 경우 그 법률의 요건과 효과가 우선하며, 표지신의칙은 이를 대체하는 새로운 책임근거가 아니라 보충적 평가원리로 기능한다.

분야별 입법례는 위험의 맥락에 따라 투명성 규율의 강도가 달라질 수 있음을 보여 준다. 「공직선거법」 제82조의8은 선거일 전 90일부터 선거일까지 선거운동을 위한 딥페이크영상등의 제작·편집·유포·상영·게시를 금지하고, 그 밖의 기간에는 해당 정보가 인공지능 기술 등을 이용하여 만든 가상정보라는 사실을 명확히 표시하도록 한다. 이는 일반적인 AI 사용사실의 고지를 넘어 선거의 공정성이라는 고위험 영역에서 금지와 표시를 결합한 규율이다. 다만 이러한 특수영역의 규율을 AI 서비스 일반에 그대로 확대할 수는 없으며, 각 법률의 목적과 적용요건을 구별하여야 한다.[28]

다음 다섯 단계는 AI-Washing이라는 독립된 위법유형의 구성요건이 아니라, 결합된 표지가 형성한 외관과 실제 서비스의 실질을 비교하기 위한 분석 순서이다. 구체적인 위법성과 법적 효과는 그 다음 단계에서 표시광고법·인공지능기본법·계약법·전문직역법 등 적용 법률의 독자적인 요건에 따라 판단한다.

---

27) 표시광고법상 전체적·궁극적 인상에 따른 오인성 판단에 관하여는 대법원 2010. 7. 22. 선고 2007다59066 판결; 「표시·광고의 공정화에 관한 법률」 제3조 제1항 제1호 및 같은 법 시행령 제3조 제1항 참조. 구체적 기능·성능 표시의 실증의무에 관하여는 같은 법 제5조 제1항 참조. 이와 관련한 행정예고안으로 공정거래위원회, 「표시·광고 실증에 관한 운영」 일부개정안 행정예고, 공정거래위원회 공고 제2026-138호, 2026. 6. 23., https://www.ftc.go.kr/www/selectBbsNttView.do?key=193&bordCd=105&nttSn=47637 (최종접속일: 2026. 8. 8.).

28) 「공직선거법」 제82조의8 제1항·제2항([시행 2026. 7. 1.] [법률 제21577호, 2026. 4. 22. 일부개정]).

<표 3> 표지-실질 정합성의 분석 순서

분석 단계	검토 물음
① 외관 형성	명칭·광고·인터페이스가 전체적으로 판단능력·전문성·책임성의 외관을 형성했는가
② 외관의 귀속	그 외관이 제공자의 표시·설계·운영 또는 방치에 귀속되는가
③ 중대한 간극	외관과 실제 기능·적용범위·검증수준·인간 관여·책임구조 사이에, 이용자의 선택·위험부담에 영향을 줄 만한 중대한 간극이 있는가
④ 외관의 교정	한계고지·출처표시·책임구조 표시가 그 외관을 실질적으로 교정했는가(고지의 시점·현저성·주표지와의 근접성·구체성·검증가능성이 그 척도)
⑤ 기대의 객관적 정당성·관련성	표지가 형성한 기대가 보통의 주의력을 가진 일반 이용자의 관점에서 객관적으로 정당하고, 이용자의 선택·위험부담과 관련되는가 (특정 집단 대상 서비스라면 그 집단의 통상적 관점도 고려)

DoNotPay 사건의 공개기록을 이 순서에 대입하면 다음과 같다. ① ‘AI lawyer’와 ‘world’s first robot lawyer’라는 명칭 및 인간 변호사처럼 법률을 개별 사안에 적용한다는 광고는 전문적 판단능력의 외관을 형성하고, ② FTC complaint가 DoNotPay가 유포하거나 유포하게 한 것으로 특정한 광고와 DoNotPay가 운영한 서비스에 비추어, 그 외관은 DoNotPay의 표시행위와 관리영역에 귀속된다고 평가할 수 있다. ③ FTC complaint가 주장한 소수의 사실입력, 포괄적·최신 법률자료의 부재, 품질·정확성 시험과 변호사 검수의 부재, 그리고 중요한 법적 쟁점의 누락·사용하기 어려운 문서에 관한 가입자 불만기록은 표시된 외관과 실제 제공조건 사이의 간극을 뒷받침하는 자료가 될 수 있으며, ④ complaint에 제시된 광고자료에서는 주표지를 실질적으로 교정할 정도의 한계고지가 드러나지 않는다. ⑤ 인간 변호사 유사성·맞춤성·전문성을 명시한 광고는 일반 이용자에게 전문적 검토에 대한 객관적으로 정당한 기대를 형성하여 구독 선택과 위험부담에 영향을 미칠 수 있다. 다만

실증자료의 부재만으로 실제 성능의 열위를 곧바로 확정해서는 안 된다. 제3단계에서는 표시 당시 합리적·객관적 근거를 보유하였는가라는 '실증의 간극'과 실제 기능이 표시된 외관에 미치지 못하였는가라는 '수행의 간극'을 구별하고, 후자는 실제 제공조건의 시험자료·오류기록·전문가 검수자료 등으로 별도로 확인하여야 한다.

여기서 '중대한 간극'은 모든 기술차이나 일시적 오류를 뜻하지 않는다. 간극은 표지가 약속한 핵심 차원—산출주체, 기능·적용범위, 성능·검증, 전문가 관여, 감독·책임구조—에 관한 것이고, 통상적 변동이나 합리적 측정불확실성을 넘어 서비스의 효용 또는 오류위험에 대한 평가를 실질적으로 바꿀 때 중대하다. 따라서 모든 분야에 공통된 오류율 수치를 두지 않고 표시된 주장과 대상 과업에 상대적으로 판단한다. 이를 판단하기 위한 자료에는 광고·서비스 화면, 실제 모델·검색·도구의 배포기록, 과업별 성능·검증자료, 인간 전문가의 검수기록 및 오류·이의제기 처리기록이 포함될 수 있다. 표시광고법이 성능주장의 오인성과 실증을 묻는다면, 이 분석은 그에 앞서 결합표지가 형성한 판단외관과 비교할 실질을 특정한다. 이 분석구조 자체가 민사상 입증책임을 전환하지는 않는다.

5. AI-Washing의 다섯 유형과 그 경계

AI-Washing은 하나의 방식으로만 나타나지 않는다. 표지와 실제 서비스의 실질 사이의 간극은 AI의 존재 여부에서부터 기술수준, 실제 수행기능과 성능, 전문자격표지의 결합, 고위험 판단에서의 역할에 이르기까지 서로 다른 층위에서 발생할 수 있다. 본고는 이러한 불일치가 주로 발생하는 지점을 기준으로 AI-Washing을 다섯 유형으로 나눈다. 이 유형들은 서로 배타적인 구성요건이 아니라 구체적인 사안에서 표지와 실질의 어긋남이 어디에서 발생하는지를 식별하기 위한 분석도구이다.

첫째, '실재 부재형'은 AI가 서비스의 결과 생성이나 핵심 기능에 실질적으로 사용되지 않음에도 AI 기반 서비스인 것처럼 표시하는 경우이다. 사람이 직접 답변을 작성하면서 이용자에게는 AI가 결과를 생성하는 것처럼 표

시하거나, 외부적으로 AI의 작동을 표방하면서 실제로는 그에 해당하는 시스템이 존재하지 않는 경우가 여기에 해당할 수 있다. 다만 인간이 결과 생성에 관여하였다는 사실만으로 이 유형이 성립하는 것은 아니다. 인간과 AI의 관여구조가 어떻게 표시되었는지, 그리고 실제 AI의 관여가 표시된 외관과 부합하는지를 함께 살펴야 한다.

둘째, '수준 과장형'은 일정한 자동화 또는 AI가 실제로 사용되기는 하지만, 그 기술적 수준이나 처리방식이 실제보다 고도화된 것처럼 표시되는 경우이다. 예컨대 제한된 규칙분기·키워드 매칭 또는 단순한 자동화 기능을 고도의 생성·추론·분석능력을 갖춘 AI인 것처럼 제시하는 경우가 이에 해당할 수 있다. 이 유형에서 문제는 법률상 또는 기술적으로 AI에 해당하는가만이 아니라, 구체적인 명칭·광고·인터페이스가 실제 시스템의 수준을 넘어 어떠한 기술적 능력의 외관을 형성하였는가에 있다.

셋째, '기능·성능·범위 과장형'은 AI가 실제로 사용되고 일정한 수준의 기능을 수행하지만, 표지가 그 기능의 내용·적용범위·정확성·최신성 또는 과업수행능력을 실제보다 넓거나 높게 나타내는 경우이다. 검색·요약 기능을 분석·추천·상담과 같은 판단기능으로 표시하거나, 제한된 자료·언어·기간에서만 검증된 기능을 일반적인 능력처럼 제시하는 경우가 대표적이다. 특정 모델과 검색도구·전문가 검수 등이 결합된 조건에서 얻은 성능을 실제 이용자에게 그러한 조건이 제공되지 않는 서비스의 성능인 것처럼 표시하는 경우도 이 유형의 판단대상이 될 수 있다. 중요한 것은 모델의 명성이나 가격 자체가 아니라 표시된 기능·성능·적용범위가 실제 제공조건에서 객관적으로 뒷받침되는가이다.

넷째, '전문신뢰 차용형'은 AI 표지가 '변호사', '의사', '약사', '세무사'와 같은 전문자격표지와 결합함으로써 해당 전문직역이 축적해 온 판단능력과 제도적 신뢰를 실제 서비스의 실질 이상으로 끌어오는 경우이다. 이 유형은 반드시 인간 전문가와 동등하다는 명시적 주장이 있는 경우에 한정되지 않는다. 결합된 명칭과 서비스의 제시방식이 전문적 판단능력뿐 아니라 자격·윤리·검토·감독·책임에 관한 외관을 형성하고, 실제 서비스에는 그에 상응하는 기능이나 제도적 구조가 존재하지 않는다면 전문신뢰 차용의 문제가 발생

할 수 있다. 인간 전문가와 동등하거나 이를 대체할 수 있다는 표시는 이러한 위험이 가장 강하게 나타나는 경우라고 할 수 있다.

다섯째, '고위험 판단 은폐형'은 AI 관여 사실 자체가 드러나거나 인정되더라도, 법률·의료·금융·세무 등에서 AI가 이용자의 생명·신체·권리·재산에 영향을 미치는 선택을 실질적으로 대체·유도하면서도 그 기능을 단순 정보제공이나 참고도구로 축소하여 표시하는 경우이다. AI의 역할이 단순 정보제공을 넘는지는 개별사실의 입력 정도, 복수 대안 중 특정 선택지의 제시 여부, 전문적 판단에 대한 합리적 신뢰의 유발 정도 및 출력과 후속행위 사이의 직접성을 종합하여 판단할 수 있다. 오류가능성, 인간 전문가의 실질적 감독 여부, 재검토·이의제기의 가능성 및 책임주체를 적절히 드러냈는지도 중요한 자료가 된다. 여기서 '고위험 판단'은 인공지능기본법 제2조 제4호의 '고영향 인공지능'과 동일한 법정개념이 아니라, AI 출력의 법익 영향과 인간 판단을 대체·유도하는 정도를 가리키는 본고의 분석개념이다.

이 다섯 유형은 서로 배타적이지 않다. 예컨대 제한된 시스템을 고도의 AI로 표시하면서 실제 기능보다 높은 정확성과 전문성을 내세우고 'AI 변호사'라는 명칭을 사용하는 서비스라면 수준 과장형, 기능·성능·범위 과장형 및 전문신뢰 차용형이 동시에 문제될 수 있다. 따라서 유형론의 목적은 하나의 서비스를 반드시 하나의 유형에 귀속시키는 데 있지 않고, 판단외관과 실제 서비스의 실질 사이에서 어떠한 종류의 불일치가 복합적으로 발생하였는지를 구체화하는 데 있다.

앞서 제시한 네 요소는 저자의 선행연구에서 제안한 정보제공과 실질적 판단지원의 경계기준을 이 논문의 고위험 판단 은폐형 분석에 맞게 전용한 것이다. 두 현상은 AI 관여의 '정도'와 산출물의 '귀속'을 구별하여 경계를 정한다. 고위험 판단 은폐형은 이용자가 AI 사용 자체는 알 수 있지만, AI의 의사결정 기여도와 위험·감독·재검토 구조를 '참고도구' 수준으로 축소하여 표시하는 경우이다. 반면 '귀속 세탁'은 AI 관련 표지 대신 결과를 인간 또는 인간 전문가의 독자적 산출물로 표시하여 산출주체를 잘못 귀속시키는 경우이다. 인간 전문가가 독립적으로 검토·수정·승인하고 내용에 책임지는 경우에는 AI를 도구로 사용했다는 사실만으로 귀속 세탁이라 할 수 없다. 하나의

서비스가 AI의 의사결정 기여도와 인간 저자성을 함께 왜곡하면 두 현상은 중첩될 수 있다. 귀속 세탁은 과장형 AI-Washing과 반대 방향으로 작동하지만 고위험 판단 은폐형과 경계를 맞대는 인접 현상이며, 구체적 책임배분은 후속과제로 남긴다.[29)]

6. 외관신뢰법리와의 구조적 접속

나태수는 인공지능 기반 플랫폼이 알고리즘의 객관성·중립성이라는 '인공지능의 권위 외관'을 형성하여 운영사업자의 지배적 거래관여를 가리고, 이를 신뢰책임과 책임귀속의 문제로 파악한다. 이에 비해 본고의 '판단외관'은 플랫폼 지배력의 은폐에 한정되지 않고, 명칭·광고·인터페이스가 판단주체·과정·근거 및 감독·책임구조에 관하여 형성하는 외관을 특정하여 실제 서비스와 비교하기 위한 개념이다. 나아가 선행연구가 신뢰책임의 성립요건과 부진정연대채무의 효과를 구성하는 데 비해, 본고는 특정한 책임효과를 도출하지 않고 개별 규율의 해석에 앞서 결합표지와 서비스 실질의 정합성을 분석하는 데 머문다.

표현대리는 대리권이 실제로 존재하는가만이 아니라 본인의 행위 등에 의하여 어떠한 권한의 외관이 형성되었는지와 상대방의 신뢰를 문제 삼는다는 점에서 중요한 유비를 제공한다. 그러나 AI 서비스에서는 전통적인 본인·대리인·상대방의 관계가 그대로 형성되지 않고, AI 자체가 독립된 법률행위의 주체가 되는 것도 아니다. 따라서 표현대리 법리를 AI-Washing에 직접 적용하거나 그 법적 효과를 확장할 수는 없다. 표현대리가 문제 삼는 것이 '권한의 외관'이라면, 본고가 AI-Washing에서 주목하는 것은 AI 또는 AI 유사 표지가 서비스의 분석·추천·진단·상담 등에 관하여 형성하는 '판단능력의 외

---

29) AI의 기능대체와 고위험성 판단기준에 관하여는 김민규, 「직업규제 영역의 인공지능 기능대체와 고위험성 판단기준—직업의 자유 제한 법리에 기초한 기능적 등가성 기준의 제안—」, 『법조』 제75권 제2호, 2026, 422-423면 참조. Humanwashing이 AI 기반 기계의 인간적 외관을 다루는 데 비해, 본고의 귀속 세탁은 AI 관여 산출물의 저자성·전문가 관여·책임 귀속을 인간의 독자적 산출물로 표시하는 경우에 한정한다. Humanwashing 논의로 Scorici, G., Schultz, M. D., & Seele, P. (2024). Anthropomorphization and Beyond: Conceptualizing Humanwashing of AI-Enabled Machines. AI & Society, 39, 789–795. https://doi.org/10.1007/s00146-022-01492-1 참조.

관'이다. 양자는 구체적 법률요건에서는 다르지만, 실체만이 아니라 거래상 형성된 외관과 그 귀속을 법적 평가대상으로 삼는다는 점에서 구조적 접점을 가진다.

명의대여자 책임과 표현대표이사 법리도 명칭이나 지위의 표시가 거래상 대방에게 영업주체·대표권·조직적 승인 등에 관한 기대를 형성할 수 있다는 점을 보여 준다. AI-Washing에서 특히 중요한 것은 이러한 외관형성 기능이 'AI'라는 기술표지와 '변호사·의사·약사·세무사' 등의 전문자격표지가 결합할 때 한층 강해질 수 있다는 점이다. 'AI 법률정보 검색'과 'AI 변호사'가 동일한 판단외관을 형성하지 않는 이유도 여기에 있다. 다만 명의대여나 표현대표이사의 법적 효과를 AI 서비스에 직접 이전할 수는 없으며, 각 제도가 요구하는 요건과 효과는 독립적으로 판단하여야 한다.[30]

현행 실정법은 이러한 외관의 일부를 각기 다른 방식으로 규율한다. 표시광고법은 개별 문구뿐 아니라 결합된 표시·광고가 소비자에게 전달하는 전체적 인상을 기준으로 거짓·과장·기만성과 사실에 관한 표시의 실증을 판단하고, 전문직역법은 각 법률이 정한 범위에서 전문자격명칭의 사용과 직역업무를 규율한다. 인공지능기본법의 투명성 규율과 계약법·약관법상의 규율도 사안에 따라 각각 적용될 수 있다. 따라서 AI-Washing이라는 이유만으로 하나의 통일된 법적 효과가 발생하는 것은 아니며, 구체적인 위법성과 책임은 해당 실정법의 요건에 따라 별도로 판단하여야 한다.[31][32]

---

30) 「상법」 제24조는 명의대여자의 책임을, 같은 법 제395조는 사장·부사장·전무·상무 기타 회사를 대표할 권한이 있는 것으로 인정될 만한 명칭을 사용한 이사의 행위에 대한 회사의 책임을 규정한다. 표현대리가 외관의 형성·귀책과 상대방의 정당한 신뢰를 중심으로 하는 외관보호책임이라는 분석으로 김상중, 「대리제도와 제3자의 보호—대리권남용과 표현대리를 중심으로」, 『비교사법』 제27권 제2호, 2020, 9-10면; 명의대여자 책임이 외관의 존재·외관 형성에 관한 귀책·제3자의 오인을 중심으로 구성된다는 분석으로 김재두, 「명의대여자의 책임」, 『법학논총』 제43권 제2호, 2019, 347면 참조.

31) 「표시·광고의 공정화에 관한 법률」 제3조 및 같은 법 시행령 제3조는 소비자를 속이거나 소비자가 잘못 알게 할 우려가 있는 거짓·과장·기만 표시·광고를 규율한다. 표시광고법상 소비자 오인 우려의 판단기준에 관하여는 김두진, 「부당한 표시·광고 행위의 위법성 판단기준」, 『소비자문제연구』 제48권 제3호, 2017, 166-173면 참조.

32) U.S. Securities and Exchange Commission, SEC Charges Two Investment Advisers with Making False and Misleading Statements About Their Use of Artificial Intelligence, Mar. 18, 2024; In the Matter of Delphia (USA) Inc., Investment Advisers Act Release No. 6573; In the Matter of Global Predictions, Inc., Investment Advisers Act Release No. 6574, https://www.sec.gov/newsroom/

판단외관은 AI 또는 AI 유사 표지가 판단주체·과정·근거 및 감독·책임구조에 관하여 형성한 객관적 외관이고, 표지-실질 정합성은 그 외관을 실제 서비스와 비교하는 분석구조이다.

표지신의칙은 이러한 분석을 구체적 법률관계의 해석에 연결하는 신의칙상의 보충적 원리이다. 민법 제2조의 신의칙은 특정 당사자 사이의 권리 행사와 의무 이행을 규율하므로, 그 자체로 사업자 일반에 새로운 표시의무를 창설하거나 개별 법률의 구성요건을 대체할 수 없다. 다만 계약교섭 또는 이용관계에서 사업자가 명칭·광고·인터페이스를 통하여 판단능력·전문가 관여·책임구조의 외관을 형성한 경우, 신의칙은 그 표시의 객관적 의미와 필요한 설명·한계고지의 범위를 해석하는 보충적 기준이 될 수 있다. 표시광고법·계약법·약관법·전문직역법이 적용되는 경우에는 각 법률의 요건과 효과가 우선한다.[33]

Ⅴ. 결론: AX 시대의 표지신의칙

본고는 AI-Washing을 단순히 AI가 실제 사용되었는지의 진위 문제로 보지 않고, AI 또는 AI 유사 표지가 형성한 판단능력·전문성·책임구조의 외관과 실제 서비스의 실질 사이의 정합성 문제로 재구성하였다. 이를 위하여 실제 서비스의 산출주체와 관여구조, 모델·배포구성, 기능·적용범위, 성능과 검증 수준 및 감독·책임구조를 비교대상으로 삼고, AI-Washing의 주요 모습을 실재 부재형, 수준 과장형, 기능·성능·범위 과장형, 전문신뢰 차용형 및 고위험 판단 은폐형으로 구분하였다.

---

press-releases/2024-36 (최종접속일: 2026. 8. 8.).

33) 민법 제2조. 표지-실질 정합성 분석 뒤의 구체적 법적 효과는 적용 실정법의 독자적인 요건에 따라 별도로 판단한다. 신의칙이 계약의 규범적·보충적 해석에 관여하는 한편 일반조항에의 의존이 확대되어서는 안 된다는 점에 관하여는 이계정, 「변호사 보수청구 제한의 근거로서 신의칙과 신인관계—법관의 합리적 재량 행사의 문제를 겸하여」, 『서울대학교 법학』 제60권 제4호, 2019, 21–22면 및 27–28면; 신의칙상 고지의무의 기준과 한계에 관하여는 대법원 2014. 7. 24. 선고 2013다97076 판결; 대법원 2023. 8. 18. 선고 2022다291702 판결 참조.

이 비교를 수행하는 도구가 판단외관의 네 층위와 표지-실질 정합성의 다섯 단계다. 판단외관은 판단 주체·과정·근거 및 감독·책임구조의 층위에서 형성되고, 그 평가는 외관 형성, 제공자 귀속, 중대한 간극, 한계고지·출처·책임표시에 의한 외관 교정, 기대의 객관적 정당성과 의사결정 관련성의 순서로 나아간다. DoNotPay 사건처럼 결합표지가 문제되는 사안에서 이 순서는 어느 표지가 어떤 기대를 만들었고 무엇이 교정되지 않았는지를 특정하는 점검표가 된다.

표지-실질 불일치만으로 특정 위법성이나 손해배상책임이 도출되지는 않는다. 본고의 기여는 결합표지의 전체적 외관, 중대한 간극과 그 입증자료를 하나의 평가단위로 특정하고, 그 결과를 표시광고법·계약법·약관법·전문직역법 등 적용 규율의 독자적 요건으로 연결하는 데 있다.

이 평가를 법질서에 이어 붙이는 고리가 표지신의칙이다. 민법 제2조의 신의성실 원칙에 기초한 이 보충적 해석원리는 표현대리·명의대여자 책임·표현대표이사로 이어져 온 외관신뢰 보호의 전통 위에 서 있되, 다루는 것은 대리권·명칭·지위가 아니라 판단능력과 전문성의 외관이라는 새 범주다. 인공지능기본법 제31조의 투명성 규율이 AI 사용 사실과 생성 출처의 인식을 보장한다면, 표지신의칙의 심사는 그 위에서 표지가 형성한 기대와 실질의 정합으로 향한다. 두 규율은 겹치지 않고 이어진다.

AI-Washing 규율은 AI 자체를 금지하거나 모든 AI 서비스에 동일한 기술구성을 요구하려는 것이 아니다. AI를 이용한 정보검색·정리·분류·문서작성 지원은 그 기능과 한계가 적절하게 표시되는 한 정당하게 활용될 수 있다. 문제는 AI 표지나 전문자격표지가 실제 기능을 넘어 더 높은 판단능력·전문성 또는 책임구조를 갖춘 것처럼 보이게 하는 경우이다. 정당한 AI 신뢰의 보호는 이용자의 신뢰가 실제 서비스의 능력과 한계에 맞게 형성되도록 표지와 실질을 정합시키는 데 있다.

본고는 구체적인 손해배상책임과 입증책임의 배분, 일반적인 성능검증·인증제도의 설계, AI 운영주체의 조직·안전관리 요건 및 귀속 세탁의 구체적 책임구조까지는 다루지 않았다. 이들 문제는 각각 별도의 논증을 필요로 한다. 본고가 제시하는 기본명제는 그보다 앞선 단계에 있다. AI-Washing의 대

안은 AI의 금지가 아니라 정직한 명명이며, 여기서 정직한 명명은 서비스가 실제로 수행하는 기능과 그 표지가 형성하는 판단외관을 서로 맞추는 것을 뜻한다.

투고일 : 2026. 06. 30.	심사일 : 2026. 07. 22.	게재확정일 : 2026. 08. 18.

참고문헌

국내문헌

강윤희, ‘변호사의 인공지능 사용과 관련한 윤리규범 — 인공지능이 변호사를 대체할 수 있을까의 관점에서’, 『경영법률』 제33권 제4호, 한국경영법률학회, 2023, 43-79면.

김두진, ‘부당한 표시·광고 행위의 위법성 판단기준’, 『소비자문제연구』 제48권 제3호, 한국소비자원, 2017, 157-186면.

김민규, ‘직업규제 영역의 인공지능 기능대체와 고위험성 판단기준 — 직업의 자유 제한 법리에 기초한 기능적 등가성 기준의 제안 —’, 『법조』 제75권 제2호, 법조협회, 2026, 401-443면.

김민정·이승민, ‘AI 정보의 표시: AI기반 콘텐츠에 대한 소비자 반응’, 『비즈니스융복합연구』 제9권 제6호, 2024, 19-25면.

김민철, ‘알고리즘 및 생성형 AI 고지의 양면적 효과에 관한 메타분석: 규제적 투명성과 설득 성과 사이의 맥락적 경계 조건을 중심으로’, 『콘텐츠와산업』 제8권 제1호, 2026, 317-321면.

김상중, ‘대리제도와 제3자의 보호 — 대리권남용과 표현대리를 중심으로’, 『비교사법』 제27권 제2호, 한국사법학회, 2020, 1-39면.

김재두, ‘명의대여자의 책임’, 『법학논총』 제43권 제2호, 단국대학교 법학연구소, 2019, 329-351면.

김정화·임동민·차호동, ‘생성형 인공지능(Generative AI) 기술의 규제 방향에 대한 입법론적 고찰 — ChatGPT 등 인공지능 시스템 생성물에 대한 표시·고지의무를 중심으로’, 『형사법의 신동향』 통권 제80호, 대검찰청, 2023, 245-283면.

김태형, ‘AI 워싱의 민사법적 책임과 대응방안 — 인공지능기본법 정의규정을 중심으로’, 『민사법의 이론과 실무』 제28권 제3호, 민사법의이론과실무학회, 2025, 125-182면.

나태수, ‘자동화된 지배적 거래관여와 인공지능의 권위 외관 — 신뢰책임론에

기초한 부진정연대채무 법리 —’,『소비자법연구』제12권 제2호, 한국소비자법학회, 2026, 139-169면.
노현숙, ‘인공지능 투명성 의무의 해석과 입법적 재구성 —「인공지능기본법」 제31조를 중심으로’,『법제』, 법제처, 2026. 6., 3-30면.
백수원, ‘헌법상 투명성원칙에 기반한 인공지능 규제의 방향’,『성균관법학』 제33권 제2호, 성균관대학교 법학연구원, 2021, 589-622면.
신의수·한재경, ‘금융상품의 그린워싱 규제에 관한 연구’,『법학논총』제55집, 숭실대학교 법학연구소, 2023, 197-232면.
신지원·김은서·이인수·사지연, ‘가전제품 표시광고에서의 AI 워싱 표현과 소비자교육이 소비자반응에 미치는 효과: 20대 소비자를 중심으로’,『소비자정책교육연구』제22권 제1호, 한국소비자정책교육학회, 2026, 45-73면.
오병철, ‘AI 에이전트에 의한 의사표시의 효력 근거’,『연세법학』제50호, 연세법학회, 2026, 305-343면.
오정하·김일환, ‘지능정보사회에서 알고리즘의 법·규제의 방향’,『법과정책』제27권 제3호, 제주대학교 법과정책연구원, 2021, 109-141면.
이계정, ‘변호사 보수청구 제한의 근거로서 신의칙과 신인관계 — 법관의 합리적 재량 행사의 문제를 겸하여’,『서울대학교 법학』제60권 제4호, 서울대학교 법학연구소, 2019, 1-57면.
조재영, ‘ESG 시대의 광고 규제 연구: 지속 가능한 녹색 소비를 위한 환경 관련 표시·광고를 중심으로’,『차세대융합기술학회논문지』제7권 제2호, 국제차세대융합기술학회, 2023, 309-317면.
최유경·김혜리, ‘E.S.G. 제도 구축의 관점에서 본 그린워싱(Greenwashing) 현황과 법제개선 방안’,『환경법연구』제45권 제1호, 한국환경법학회, 2023, 105-146면.

외국문헌

Akerlof, G. A. (1970). The market for 'lemons': Quality uncertainty and the market mechanism. The Quarterly Journal of Economics, 84(3), 488-

500. https://doi.org/10.2307/1879431

Elsayed, N. (2026). AI washing and the erosion of digital legitimacy: A socio-technical perspective on responsible artificial intelligence in business. arXiv preprint arXiv:2601.06611 [cs.HC]. https://doi.org/10.48550/arXiv.2601.06611

Emons, W. (1997). Credence goods and fraudulent experts. RAND Journal of Economics, 28(1), 107–119. https://doi.org/10.2307/2555942

Hovland, C. I., & Weiss, W. (1951). The influence of source credibility on communication effectiveness. Public Opinion Quarterly, 15(4), 635–650. https://doi.org/10.1086/266350

Lee, J. D., & See, K. A. (2004). Trust in automation: Designing for appropriate reliance. Human Factors, 46(1), 50–80. https://doi.org/10.1518/hfes.46.1.50_30392

Meyer, J. W., & Rowan, B. (1977). Institutionalized organizations: Formal structure as myth and ceremony. American Journal of Sociology, 83(2), 340–363. https://doi.org/10.1086/226550

Nass, C., Steuer, J., & Tauber, E. R. (1994). Computers are social actors. In Proceedings of the SIGCHI Conference on Human Factors in Computing Systems (pp. 72–78). ACM. https://doi.org/10.1145/259963. 260288

Scorici, G., Schultz, M. D., & Seele, P. (2024). Anthropomorphization and beyond: Conceptualizing humanwashing of AI-enabled machines. AI & Society, 39, 789–795. https://doi.org/10.1007/s00146-022-01492-1

Spence, M. (1973). Job market signaling. The Quarterly Journal of Economics, 87(3), 355–374. https://doi.org/10.2307/1882010

Weber-Wulff, D., Anohina-Naumeca, A., Bjelobaba, S., Foltýnek, T., Guerrero-Dib, J., Popoola, O., Šigut, P., & Waddington, L. (2023). Testing of detection tools for AI-generated text. International Journal for Educational Integrity, 19, Article 26. https://doi.org/10.1007/s40979-023-00146-z

<국문요약>

AI는 왜 믿음을 얻는가
– AI-Washing, 판단외관, 그리고 AX 시대의 표지신의칙 –

김 민 규

인공지능 전환(AX)이 확산되는 상황에서 이 글은 AI-Washing을 어떤 상품이나 서비스가 ‘AI를 사용한다’는 거짓 표시의 문제로 좁히지 않고, AI 또는 AI 유사 표지가 형성한 외관이 그 서비스의 실제 기능·적용범위·검증수준·한계·책임구조와 어긋날 때 이용자가 갖게 되는 판단능력·전문성·책임에 관한 기대가 왜곡되는 현상으로 다시 규정한다. 물음의 초점은 AI 사용 여부의 진위가 아니라 표지가 끌어온 기대와 실질 사이의 간극에 있다. 같은 ‘AI’ 표지라도 정보정리에 쓰일 때와 법률·의료·세무의 판단을 대신하는 듯 보일 때는 전혀 다른 무게로 평가되어야 한다.

본고는 이 현상을 “우주”·“컴퓨터”·“나노”·“바이오”로 이어져 온 혁신표지의 계보 위에 놓는다. AI-Washing은 갑자기 돌출한 신종 기법이 아니라 표지와 실질의 불일치라는 되풀이된 문제의 한 매듭이다. 다만 앞선 표지들이 주로 기능의 향상을 약속했다면, AI 표지는 자율성·맥락이해·사안별 결론에 대한 기대, 곧 판단능력에 관한 기대를 더 직접적이고 밀도 높게 형성한다는 점에서 갈라진다.

본고는 그 중심에 ‘판단외관’ 개념을 둔다. 판단외관은 AI 또는 AI 유사 표지가 누가 판단하는지, 어떠한 과정을 거치는지, 무엇을 근거로 하는지, 그리고 그 판단이 어떠한 감독과 책임구조 아래 놓이는지에 관하여 형성하는 객관적 외관을 말한다. 이에 따라 판단외관은 판단 주체, 판단 과정, 판단 근거 및 감독·책임구조의 네 층위로 구분된다. 본고는 이러한 외관을 실제 서

비스의 산출주체·관여구조, 모델·배포구성, 기능·적용범위, 성능·과업적합성·검증 및 감독·책임구조라는 다섯 좌표와 비교한다.

문제는 “AI 변호사”·“AI 의사”·“AI 세무사”처럼 AI 표지가 전문자격표지와 결합할 때 한층 까다로워진다. 이러한 결합표지는 도구에 대한 설명이 아니라 자격·윤리·징계·책임으로 쌓아 올린 제도적 신뢰를 조용히 차용하면서, “AI”라는 수식어로 사칭에 가까운 외양을 누그러뜨린다. 인간 전문가가 아님을 아는 이용자조차 전문직 수준의 판단을 기대할 수 있고, AI-Washing은 바로 그 기대와 실제 사이의 틈에 자리한다.

본고가 제안하는 표지신의칙은 AI-Washing이라는 새로운 위법유형이나 독립된 손해배상책임을 창설하지 않는다. 판단외관을 특정하고 이를 실제 서비스와 비교한 뒤, 개별 사안에 적용되는 표시광고법·계약법·약관법·전문직역법의 요건을 해석할 때 결합된 표지의 전체적 외관과 실질의 정합성을 고려하도록 하는 보충적 평가원리이다. 이 원리가 보호하려는 것은 AI에 대한 막연한 기대가 아니라 정당한 AI 신뢰, 곧 실질에 근거를 둔 신뢰다. 서비스가 실제로 수행하는 기능과 그 한계에 맞게 형성된 신뢰는 보호의 대상이 되지만, 표지가 실제보다 높은 판단능력이나 전문성을 암시하여 만들어 낸 왜곡된 신뢰는 같은 보호를 요구할 수 없다는 것이 본고의 출발점이자 결론이다.

분석 결과 AI-Washing은 실질적 AI 사용이 없는 실재 부재형, 기술수준·처리방식을 부풀리는 수준 과장형, 과업·성능·적용범위를 넓히는 기능·성능·범위 과장형, 자격·감독·책임의 외관을 차용하는 전문신뢰 차용형 및 AI의 실질적 의사결정 기여도를 단순 정보·참고도구 수준으로 축소하는 고위험 판단 은폐형으로 나타나며, 한 서비스에서 중첩될 수 있다. 표지-실질 정합성은 외관 형성, 제공자 귀속, 외관과 실질 사이의 중대한 간극, 한계고지·출처·책임표시에 의한 외관 교정 및 기대의 객관적 정당성과 의사결정 관련성의 순서로 분석한다. 한편 AI 관여 산출물의 산출주체를 인간 또는 인간 전문가에게 잘못 귀속하여 그들의 독자적 산출물처럼 표시하는 ‘귀속 세탁’은 과장형 AI-Washing과 반대 방향으로 작동하면서 고위험 판단 은폐형과 경계를 맞대는 인접 현상으로 구별된다.

주제어: AI-Washing, 판단외관, 표지신의칙, 외관신뢰법리, AX(인공지능 전환), AIoid

<Abstract>

Why AI Earns Trust
- AI-Washing, the Appearance of Judgment, and Good Faith in Labeling in the Age of AI Transformation (AX)

영문이름

In the age of AI transformation (AX), this Article reframes AI-Washing not merely as a false claim that a product or service 'uses AI,' but as a distortion of user expectations about judgment capacity, expertise, and responsibility, triggered when the appearance formed by an AI or AI-like label diverges from the actual function, scope, limits, and accountability structure of the service in question. It situates this problem within a longer genealogy of innovation labels—such as 'space,' 'computer,' 'nano,' and 'bio'—while arguing that AI is distinctive because it evokes not merely improved functionality but judgment capacity.

The Article develops the concept of the appearance of judgment: the objective appearance created by AI or AI-like labels as to who is judging, how the judgment is made, what supports it, and under what supervision and accountability structure it operates. It distinguishes four layers—the appearance of the judging subject, the judgment process, the evidential basis, and supervision and accountability—and compares them with five features of the actual service: the source of the output and human involvement; the model and deployment configuration; function and scope; performance, task fitness, and validation; and supervision and accountability.

The problem becomes more acute when AI labels are combined with professional-credential labels: “AI lawyer,” “AI doctor,” and “AI tax adviser.” Such hybrid labels may draw on institutional trust accumulated through licensing, ethical duties, disciplinary regimes, and professional liability. Even users who know that the service is not a human professional may infer professional-grade judgment, creating a gap between expected and actual performance.

The analysis identifies five recurring forms of AI-Washing: absence of material AI involvement; overstatement of technological level or processing; exaggeration of task, performance, or scope; borrowing of professional trust in qualification, supervision, or responsibility; and understatement of AI’s material decisional contribution as mere information or reference support in high-risk contexts. These forms may overlap. The Article then proposes a five-step analysis—formation of the appearance, attribution to the provider, a material gap between appearance and substance, correction through adequate disclosure, and the objective justification and decision relevance of the expectation. The good-faith principle of labeling is not an independent cause of action; it is a supplementary interpretive principle that operates before the requirements and effects of the applicable statutory or private-law regime are determined. What it protects is not diffuse enthusiasm for AI but justified AI trust, that is, trust grounded in what the service actually does; trust distorted by labels suggesting greater judgment capacity or expertise than the service provides cannot claim the same protection.

The Article also distinguishes attribution washing—misattributing the source of an AI-assisted output by presenting it as independently human or professional work—as an adjacent phenomenon that reverses exaggeration-based AI-Washing while bordering the high-risk concealment category. The alternative to AI-Washing is not a ban on AI, but honest naming that aligns the service’s actual capabilities with the appearance it

creates.

Key Words: AI-Washing, appearance of judgment, good-faith principle of labeling, doctrines protecting reliance on appearances, AI Transformation (AX), AIoid